

**ETAPA 3 · INFORME TÉCNICO DEL PROCESO ETL EN SQL SERVER
INTEGRATION SERVICES**

MINERÍA DE DATOS

EDISON GUSTAVO CAÑON VARELA

DAVID SANTIAGO TORRES HIGUERA

LUIS FELIPE MURCIA ROJAS

PAULA CATALINA ANGEL PARRA

ESTEFFFY GERALDINE BACHILLER CARRILLO

UNIVERSIDAD DE CUNDINAMARCA

EXTENSION CHIA

25 DE SEPTIEMBRE DEL 2026

Contenido

1. Introducción y alcance	4
2. Diagnóstico inicial y reglas de tratamiento	4
Diagnóstico inicial	4
Reglas de tratamiento definidas.....	5
3. Diseño del Control Flow	7
4. Diseño del Data Flow	9
5. Configuración paso a paso de los componentes.....	12
Administradores de conexión.....	12
DER_IdCarga (Derived Column)	12
MC_Bifurcar (Multicast)	12
DEST_Staging (OLE DB Destination).....	13
DER_NoAplica (Derived Column).....	13
RC_AntesSort / RC_DespuesSort / RC_Aceptadas / RC_Revision / RC_YaExistian (Row Count)	13
CONV_Tipos (Data Conversion).....	13
DER_Atipicos (Derived Column)	13
LKP_TipoEvento (Lookup).....	14
SORT_Duplicados (Sort)	14
LKP_Idempotencia (Lookup)	14
DER_MotivoConversion / DER_MotivoTipoEvento / DER_MotivoFecha (Derived Column)	14
6. Evidencias de ejecución de las tres iteraciones	16
Iteración 1 · Línea base: tipos y duplicados	16
Iteración 2 · Reglas completas	19
Iteración 3 · Repetibilidad e idempotencia	20
Resumen de las iteraciones.....	22
7. Manejo de errores y tratamiento de los registros en revisión	22
Estrategia.....	22
Estructura del registro en revisión.....	22
Composición de los 5.805 registros en revisión.....	23
Procedimiento de tratamiento	23
8. Comparación de resultados	23
Conteos	23

Indicadores de calidad	24
9. Evidencia de que repetir el mismo lote no genera duplicados	24
10. Enlaces	25
11. Conclusiones y mejoras propuestas.....	25

1. Introducción y alcance

Este informe documenta la Etapa 3 del proyecto: la construcción de un proceso ETL en SQL Server Integration Services (SSIS) que toma el dataset consolidado generado en las etapas anteriores, aplica las reglas de tratamiento definidas a partir del diagnóstico de calidad y carga el resultado en una base de datos relacional, separando los registros que no cumplen las reglas en una tabla de revisión.

Herramientas	Visual Studio con extensión de Integration Services (SQL Server 2025), SQL Server LocalDB (localdb)\MSSQLLocalDB, sqlcmd.
Origen	data/processed/dataset_consolidado.csv 337.444 registros 23 columnas
Destino	Base DesaparicionPersonasETL con esquemas <i>staging</i> , <i>ref</i> , <i>revision</i> , <i>control</i> y <i>dbo</i> .
Paquete	etl/ssis/ETL_Principal.dtsx
Scripts SQL	etl/sql/01_crear_esquema.sql a 05_final_y_revision.sql
Iteraciones	Tres: (1) línea base de tipos y duplicados; (2) reglas completas; (3) prueba de repetibilidad e idempotencia.

2. Diagnóstico inicial y reglas de tratamiento

Diagnóstico inicial

El perfilamiento de la Etapa 2 sobre el dataset consolidado identificó los siguientes problemas, que son el punto de partida del diseño del ETL:

Tabla 1. Problemas del diagnóstico inicial (Etapa 2).

Problema	Variable	Registros afectados	Dimensión
Duplicados por <i>id_original</i> + <i>fuentes</i> (todos en SIEVCAC)	<i>id_original</i> , <i>fuentes</i>	28	Unicidad
Fecha faltante (el registro no puede ubicarse en el tiempo con precisión)	<i>fecha</i>	5.808 (1,72 %)	Complejidad
Categoría con carácter invisible NBSP ('Desplazamiento\xa0') y variantes de texto libre de la encuesta	<i>tipo_evento</i>	11 valores únicos	Consistencia / validez
Nulos estructurales: la columna no aplica por diseño a esa fuente	<i>region</i> , <i>departamento</i> , <i>municipio</i>	<i>region</i> 288.439; <i>depto.</i> 49.019; <i>mun.</i> 49.005	Complejidad
Todas las columnas llegan como texto desde el CSV	numéricas y <i>fecha</i>	337.444	Validez (tipo)
Valores atípicos por regla IQR (legítimos en eventos agregados)	<i>num_personas</i> , <i>año</i>	13.390 y 665	Exactitud (a validar)

Indicadores de partida: completitud global **78,50 %** (1.668.816 celdas nulas de 7.761.212), unicidad **99,99 %**, 100 % de fechas no nulas en formato YYYY-MM-DD y 100 % de coordenadas y meses dentro de rango.

Reglas de tratamiento definidas

#	Regla	Componente SSIS	Qué hace con el registro
R1	Trazabilidad: toda fila recibida se conserva sin cambios, marcada con la carga	DER_IdCarga, MC_Bifurcar, DEST_Staging	Copia cruda en staging.desaparecidos_raw
R2	Nulos estructurales se marcan como 'No aplica'	DER_NoAplica	Corrige: <i>region</i> (fuentes no globales), <i>departamento</i> y <i>municipio</i> (fuentes globales)
R3	Tipado: <i>num_personas</i> , <i>edad</i> , <i>año</i> , <i>mes</i> , <i>fecha</i> , <i>latitud</i> , <i>longitud</i> y códigos DANE	CONV_Tipos	Si no convierte: a revisión con motivo 'Error de conversión en columna #n'


R4	Atípicos se marcan, no se eliminan (num_personas > 1; anio < 1974 según IQR)	DER_Atipicos	Agrega banderas num_personas_atipico y anio_atipico
R5	Homologación de tipo_evento contra catálogo	LKP_TipoEvento	Sin coincidencia: a revisión con motivo 'tipo_evento no encontrado en catalogo'
R6	Unicidad por id_original + fuente	SORT_Duplicados	Elimina la repetición y la cuenta (RC_AntesSort - RC_DespuesSort)
R7	Fecha obligatoria para la tabla final	CSPL_FechaFaltante	Sin fecha: a revisión con motivo 'fecha faltante'
R8	Idempotencia: no insertar lo que ya existe en la tabla final	LKP_Idempotencia	Si id_registro ya existe: se cuenta en RC_YaExistian y no se inserta
R9	Bitácora de cada ejecución	Iniciar carga, Calcular duplicados, Cerrar carga	Fila en control.control_cargas con los conteos

Estructura de la base de datos		
Esquema tabla	Script	Propósito
staging.desaparecidos_raw	02_stating.sql	Espejo 1:1 del CSV, todo NVARCHAR, más id_carga y fecha_carga.
ref.tipo_evento_homologado	03_referencia_tipo_evento.sql	Catálogo valor_origen → valor_canonico (11 filas; incluye 'Desplazamiento'+NCHAR(160)).

control.control_cargas	04_control_cargas.sql	Bitácora: iteración, recibidos, aceptados, duplicados, revisión.
dbo.desaparecidos_final	05_final_y_revision.sql	Tabla limpia y tipada; UNIQUE(id_registro); banderas de atípicos; id_carga
revision.desaparecidos_pendi entes	05_final_y_revision.sql	Cuarentena: campo_conflictivo, valor_original, motivo_revision, id_carga.

3. Diseño del Control Flow

El flujo de control orquesta una ejecución completa y deja constancia de ella. Las tareas se encadenan con restricciones de precedencia de tipo *Éxito*. Si una falla, las siguientes no se ejecutan y la carga queda abierta en control_cargas, lo que facilita detectar ejecuciones incompletas.




Tareas del Control Flow.

Tarea	Tipo	Función
Iniciar carga	Execute SQL Task	INSERT INTO control.control_cargas (iteracion, archivo_origen) OUTPUT INSERTED.id_carga VALUES (?, ...). Recibe User::Iteracion y guarda el resultado (fila única) en User::IdCarga.
ETL Iteracion 1	Data Flow Task	Versión simplificada usada en la iteración 1 (tipos + duplicados). Desde la iteración 2 queda deshabilitada; SSIS la omite y continúa con la siguiente tarea.
ETL Principal	Data Flow Task	Flujo de datos con todas las reglas (sección 4).
Calcular duplicados	Expression Task	$@[User::FilasDuplicadas] = @[User::FilasAntesSort] - @[User::FilasDespuesSort]$
Cerrar carga	Execute SQL Task	UPDATE control.control_cargas SET registros_recibidos = ?, registros_aceptados = ?, registros_duplicados = ?, registros_revision = ? WHERE id_carga = ?

Variables del paquete.


Variable	Tipo	Uso
User::Iteracion	Int32	Número de iteración que se registra (1, 2 o 3). Se cambia antes de cada ejecución.

User::IdCarga	Int32	Identificador de la carga; se agrega a cada fila (DER_IdCarga).
User::FilasAntesSort / FilasDespuesSort	Int32	Conteos antes y después de eliminar duplicados.
User::FilasDuplicadas	Int32	Diferencia calculada por la Expression Task.
User::FilasAceptadas	Int32	Filas nuevas insertadas en la tabla final.
User::FilasRevision	Int32	Filas enviadas a revision.desaparecidos_pendientes.
User::FilasYaExistian	Int32	Filas descartadas por idempotencia.



4. Diseño del Data Flow

El Data Flow **ETL Principal** tiene un camino principal que valida y transforma los registros hasta la tabla final, una copia paralela a staging y una rama de revisión que recoge, con su motivo, las filas que no cumplen alguna regla. Los conteos de la figura corresponden a la iteración 2.



Recorrido de una fila:

-Lectura y marca de carga. ORIGEN_CSV lee el archivo y DER_IdCarga agrega *id_carga*. MC_Bifurcar duplica el flujo: una copia va sin cambios a staging (R1).


-Corrección y tipado. DER_NoAplica marca los nulos estructurales (R2) y CONV_Tipos convierte a tipos numéricos y fecha (R3); si una conversión falla, la fila sale por el *Error Output* hacia revisión.

-Marcas y homologación. DER_Atipicos agrega las banderas (R4) y LKP_TipoEvento reemplaza el tipo de evento por su valor canónico (R5).


-Unicidad y completitud. SORT_Duplicados elimina repeticiones (R6) y CSPL_FechaFaltante separa las filas sin fecha (R7).

-Carga idempotente. LKP_Idempotencia busca el id_registro en la tabla final: solo las filas que no existen llegan a DEST_Final (R8).

-Revisión. Las tres salidas de rechazo pasan por un Derived Column que escribe *campo_conflictivo*, *valor_original* y *motivo_revision*, se unen en Union All y se cargan en revision.desaprecidos_pendientes.



Inicio del Data Flow: origen, marca de carga y bifurcación.



conversión de tipos, atípicos, homologación y duplicados.

5. Configuración paso a paso de los componentes

Los valores de esta sección se tomaron directamente del paquete ETL_Principal.dtsx. Para cada componente se indica cómo se configuró y qué función cumple dentro del proceso.

- Administradores de conexión

CM_CSV_Consolidado	Flat File. Formato delimitado, calificador de texto ", página de códigos 65001 (UTF-8) , nombres de columna en la primera fila, delimitador de fila CRLF. Anchos ajustados al largo real (p. ej. id_registro 50, tipo_evento 100, detalle 500, narrativa 1000) en lugar de 4000.
CM_SQL	OLE DB (MSOLEDBSQL) a (localdb)\MSSQLLocalDB, catálogo DesaparicionPersonasETL, seguridad integrada de Windows . No se guarda usuario ni contraseña en el paquete.

- ORIGEN_CSV (Flat File Source)

Función: Lee el CSV consolidado.

Conexión	CM_CSV_Consolidado
Retain null values	Activado (RetainNulls = true). Sin esta opción los campos vacíos llegaban como texto vacío y fallaba la conversión (ajuste de la iteración 1).
Salida de error	Falla el componente (el archivo debe tener la estructura esperada).

- DER_IdCarga (Derived Column)

Función: Agrega el número de carga a cada fila para rastrearla en staging, final y revisión.

Nueva Columna	<code>id_carga = (DT_I4)[User::IdCarga]</code>
----------------------	--

- MC_Bifurcar (Multicast)

Función: Envía la misma fila a dos destinos sin copiar lógica: staging (datos crudos) y la rama de limpieza.

Salidas	Salida 1 → DEST_Staging; Salida 2 → DER_NoAplica.
----------------	---

- DEST_Staging (OLE DB Destination)

Función: Guarda la copia sin transformar de lo recibido en cada carga.

Tabla	staging.desaparecidos_raw
Modo de acceso	Tabla o vista – carga rápida (AccessMode 3), opciones TABLOCK, CHECK_CONSTRAINTS.
Asignación	Las 23 columnas del CSV + id_carga; fila_staging_id y fecha_carga se generan en SQL.

- DER_NoAplica (Derived Column)

Función: Distingue un vacío estructural (la variable no existe en esa fuente) de un dato faltante real. Reemplaza las columnas existentes.

region	(nivel_fuente != "Global" ISNULL(region)) ? "No aplica" : region
departamento	(nivel_fuente == "Global" && ISNULL(departamento)) ? "No aplica" : departamento
municipio	(nivel_fuente == "Global" && ISNULL(municipio)) ? "No aplica" : municipio

- RC_AntesSort / RC_DespuesSort / RC_Aceptadas / RC_Revision / RC_YaExistian (Row Count)

Función: Cuentan las filas que pasan por cada punto y alimentan la bitácora.

Variables	User::FilasAntesSort, FilasDespuesSort, FilasAceptadas, FilasRevision y FilasYaExistian respectivamente.
------------------	--

- CONV_Tipos (Data Conversion)

Función: Convierte a su tipo definitivo las columnas que llegan como texto.

Conversiones	num_personas → DT_I4; edad → DT_I2; anio → DT_I2; mes → DT_UI1; fecha → DT_DBDATE; latitud y longitud → DT_DECIMAL escala 6; codigo_dane_departamento y codigo_dane_municipio → DT_I4.
Error y truncamiento	Redirigir fila en todas las columnas convertidas: la fila con error sale por <i>Data Conversion Error Output</i> hacia DER_MotivoConversion, en lugar de detener el paquete.

- DER_Atipicos (Derived Column)

Función: Marca los valores atípicos para revisión analítica sin eliminarlos.

num_personas_atipico	!ISNULL(num_personas_conv) && num_personas_conv > 1
anio_atipico	!ISNULL(anio_conv) && anio_conv < 1974 (límite inferior IQR: $2001 - 1,5 \times 18 = 1974$)

- LKP_TipoEvento (Lookup)

Función: Homologa el tipo de evento con el catálogo de referencia.

Referencia	select * from [ref].[tipo_evento_homologado], caché completa.
Unión	tipo_evento (flujo) = valor_origen (catálogo); devuelve valor_canonico como tipo_evento_canonico.
Sin coincidencia	Redirigir filas a la salida sin coincidencia → DER_MotivoTipoEvento.

- SORT_Duplicados (Sort)

Función: Elimina los registros repetidos.

Claves de orden	1: id_original; 2: fuente.
Quitar filas con valores de orden duplicados	Activado. Las demás columnas pasan como columnas de paso.

- CSPL_FechaFaltante (Conditional Split)

Función: Separa los registros sin fecha.

Condición 'SinFecha'	ISNULL(fecha_conv) → DER_MotivoFecha
Salida predeterminada	'Continua' → LKP_Idempotencia

- LKP_Idempotencia (Lookup)

Función: Garantiza que repetir la carga no duplique la tabla final.

Referencia	select * from [dbo].[desaparecidos_final]
Unión	id_registro = id_registro
Salidas	Coincidencia → RC_YaExistian (no se inserta). Sin coincidencia → RC_Aceptadas → DEST_Final.

- DER_MotivoConversion / DER_MotivoTipoEvento / DER_MotivoFecha (Derived Column)


Función: Dan formato común a los rechazos para la tabla de revisión.

Conversión	campo_conflictivo = "conversion_tipos"; motivo_revision = "Error de conversion en columna #" + ErrorColumnn; valor_original = tipo_evento
Tipo de evento	campo_conflictivo = "tipo_evento"; motivo_revision = "tipo_evento no encontrado en catalogo de homologacion"; valor_original = tipo_evento
Fecha	campo_conflictivo = "fecha"; motivo_revision = "fecha faltante"; valor_original = "(vacio)"


- Union All, DEST_Final y DEST_Revision

Función: Unen los rechazos y cargan los destinos.

Union All	Une las tres ramas de rechazo en un solo flujo hacia RC_Revision.
DEST_Final	dbo.desaparecidos_final; carga rápida con TABLOCK y CHECK_CONSTRAINTS; se asignan las columnas *_conv, el tipo homologado y las banderas.
DEST_Revision	revision.desaparecidos_pendientes; misma configuración de carga rápida.



Conditional Split de fecha faltante e idempotencia en el Data Flow.



Rama de revisión: Union All, RC_Revision y DEST_Revision.

6. Evidencias de ejecución de las tres iteraciones

Cada iteración se registró en control.control_cargas. Antes de las iteraciones 2 y 3 se vaciaron las tablas final, revisión y staging para comparar en igualdad de condiciones; la tabla de control no se vació porque guarda el historial.


Iteración 1 · Línea base: tipos y duplicados

Objetivo. Cargar el dataset con tipos correctos y sin duplicados, usando la versión simplificada del flujo (ETL Iteracion 1).


Ajustes realizados.

- **Todas las filas iban a revisión** en el primer intento: los campos vacíos llegaban como cadena vacía y no se podían convertir a número. Se activó *Retain null values* en ORIGEN_CSV.
- **El Sort tardaba demasiado** porque todas las columnas tenían ancho 4000. Se midió el largo real de cada columna con una consulta sobre staging y se ajustaron los anchos en el administrador de conexión; el tiempo bajó a unos pocos minutos.


Resultado. 337.444 recibidos, **337.416 aceptados**, 28 duplicados, 0 en revisión.




Control Flow de la iteración 1 (ETL Iteracion 1 activa).



Data Flow de la iteración 1: lectura, marca de carga y bifurcación.



conversión de tipos y eliminación de duplicados (337.444 → 337.416).



Iteración 1: idempotencia y carga final (337.416 filas).

control.contr...cargas [Datos] ETL_Principal.dtsx [Diseño]											
	id_carga	iteracion	fecha_ejecucion	archivo_origen	registros_recib...	registros_acep...	registros_dupli...	registros_revisi...	completitud_p...	completitud_p...	notas
▶	1	1	22/09/2026 10:1...	data/processed...	337444	337416	28	0	NULL	NULL	NULL
⊕	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL

control.control_cargas después de la iteración 1.

	id_registro	id_original	fuentes	nivel_fuente	unidad_de_an...	num_personas	tipo_evento	estado_victima	sexo	edad	año	mes
▶	2020-MMMP00278	2020-MMMP00278	IOM Missing M...	Global	evento_agregado	1	Desaparicion/...	Aparecido sin v...	Sin informacion	NULL	2020	4
	2020-MMMP00279	2020-MMMP00279	IOM Missing M...	Global	evento_agregado	1	Desaparicion/...	Aparecido sin v...	Sin informacion	NULL	2020	4
	2020-MMMP00280	2020-MMMP00280	IOM Missing M...	Global	evento_agregado	1	Desaparicion/...	Aparecido sin v...	Sin informacion	NULL	2020	4
	2020-MMMP00281	2020-MMMP00281	IOM Missing M...	Global	evento_agregado	1	Desaparicion/...	Aparecido sin v...	Sin informacion	NULL	2020	4
	2020-MMMP00282	2020-MMMP00282	IOM Missing M...	Global	evento_agregado	1	Desaparicion/...	Aparecido sin v...	Sin informacion	NULL	2020	4
	2020-MMMP00283	2020-MMMP00283	IOM Missing M...	Global	evento_agregado	1	Desaparicion/...	Aparecido sin v...	Sin informacion	NULL	2020	4
	2020-MMMP00284	2020-MMMP00284	IOM Missing M...	Global	evento_agregado	1	Desaparicion/...	Aparecido sin v...	Sin informacion	NULL	2020	4
	2020-MMMP00285	2020-MMMP00285	IOM Missing M...	Global	evento_agregado	1	Desaparicion/...	Aparecido sin v...	Sin informacion	NULL	2020	4
	2020-MMMP00286	2020-MMMP00286	IOM Missing M...	Global	evento_agregado	1	Desaparicion/...	Aparecido sin v...	Sin informacion	NULL	2020	4
	2020-MMMP00287	2020-MMMP00287	IOM Missing M...	Global	evento_agregado	1	Desaparicion/...	Aparecido sin v...	Sin informacion	NULL	2020	4
	2020-MMMP00288	2020-MMMP00288	IOM Missing M...	Global	evento_agregado	1	Desaparicion/...	Aparecido sin v...	Sin informacion	NULL	2020	4
	2020-MMMP00289	2020-MMMP00289	IOM Missing M...	Global	evento_agregado	1	Desaparicion/...	Aparecido sin v...	Sin informacion	NULL	2020	4
	2020-MMMP00290	2020-MMMP00290	IOM Missing M...	Global	evento_agregado	1	Desaparicion/...	Aparecido sin v...	Sin informacion	NULL	2020	4
	2020-MMMP00291	2020-MMMP00291	IOM Missing M...	Global	evento_agregado	1	Desaparicion/...	Aparecido sin v...	Sin informacion	NULL	2020	4
	2020-MMMP00292	2020-MMMP00292	IOM Missing M...	Global	evento_agregado	1	Desaparicion/...	Aparecido sin v...	Sin informacion	NULL	2020	4
	2020-MMMP00293	2020-MMMP00293	IOM Missing M...	Global	evento_agregado	1	Desaparicion/...	Aparecido sin v...	Sin informacion	NULL	2020	4

dbo.desaparecidos_final con campos numéricos y fecha tipados y NULL reales.

revision.des...entes [Datos] dbo.desaparec..._final [Datos] control.contr...cargas [Datos] ETL_Principal.dtsx [Diseño]										
	revisión_id	id_registro	id_original	fuentes	campo_conflic...	valor_original	motivo_revisión	fila_completa...	id_carga	fecha_proceso
⊕	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL

revision.desaparecidos_pendientes vacía en la iteración 1.

id_staging_id	id_carga	fecha_carga	id_registro	id_original	fuerate	nivel_fuerate	unidad_de_an...	num_personas	tipo_evento	estado_victima	sexo
972	1	22/09/2026 10:1...	IOIM-2015.MMM...	2015.MMP00443	IOIM Missing M...	Global	evento_agregado	22	Desapacion/...	Fallecido y desa...	Sin info
973	1	22/09/2026 10:1...	IOIM-2015.MMM...	2015.MMP00444	IOIM Missing M...	Global	evento_agregado	1	Desapacion/...	Aparecido sin v...	Sin info
974	1	22/09/2026 10:1...	IOIM-2015.MMM...	2015.MMP00446	IOIM Missing M...	Global	evento_agregado	1	Desapacion/...	Aparecido sin v...	Sin info
975	1	22/09/2026 10:1...	IOIM-2015.MMM...	2015.MMP00447	IOIM Missing M...	Global	evento_agregado	1	Desapacion/...	Aparecido sin v...	Sin info
976	1	22/09/2026 10:1...	IOIM-2015.MMM...	2015.MMP00448	IOIM Missing M...	Global	evento_agregado	1	Desapacion/...	Aparecido sin v...	Sin info
977	1	22/09/2026 10:1...	IOIM-2015.MMM...	2015.MMP00449	IOIM Missing M...	Global	evento_agregado	6	Desapacion/...	Fallecido y desa...	Sin info
978	1	22/09/2026 10:1...	IOIM-2015.MMM...	2015.MMP00450	IOIM Missing M...	Global	evento_agregado	1	Desapacion/...	Aparecido sin v...	Sin info
979	1	22/09/2026 10:1...	IOIM-2015.MMM...	2015.MMP00451	IOIM Missing M...	Global	evento_agregado	3	Desapacion/...	Aparecido sin v...	Sin info
980	1	22/09/2026 10:1...	IOIM-2015.MMM...	2015.MMP00452	IOIM Missing M...	Global	evento_agregado	1	Desapacion/...	Aparecido sin v...	Sin info
981	1	22/09/2026 10:1...	IOIM-2015.MMM...	2015.MMP00453	IOIM Missing M...	Global	evento_agregado	2	Desapacion/...	Aparecido sin v...	Sin info
982	1	22/09/2026 10:1...	IOIM-2015.MMM...	2015.MMP00454	IOIM Missing M...	Global	evento_agregado	2	Desapacion/...	Aparecido sin v...	Sin info
983	1	22/09/2026 10:1...	IOIM-2015.MMM...	2015.MMP00455	IOIM Missing M...	Global	evento_agregado	2	Desapacion/...	Aparecido sin v...	Sin info
984	1	22/09/2026 10:1...	IOIM-2015.MMM...	2015.MMP00456	IOIM Missing M...	Global	evento_agregado	1	Desapacion/...	Aparecido sin v...	Sin info
985	1	22/09/2026 10:1...	IOIM-2015.MMM...	2015.MMP00457	IOIM Missing M...	Global	evento_agregado	2	Desapacion/...	Aparecido sin v...	Sin info
986	1	22/09/2026 10:1...	IOIM-2015.MMM...	2015.MMP00458	IOIM Missing M...	Global	evento_agregado	1	Desapacion/...	Aparecido sin v...	Sin info
987	1	22/09/2026 10:1...	IOIM-2015.MMM...	2015.MMP00459	IOIM Missing M...	Global	evento_agregado	3	Desapacion/...	Aparecido sin v...	Sin info
988	1	22/09/2026 10:1...	IOIM-2015.MMM...	2015.MMP00460	IOIM Missing M...	Global	evento_agregado	1	Desapacion/...	Aparecido sin v...	Sin info
989	1	22/09/2026 10:1...	IOIM-2015.MMM...	2015.MMP00461	IOIM Missing M...	Global	evento_agregado	2	Desapacion/...	Aparecido sin v...	Sin info
990	1	22/09/2026 10:1...	IOIM-2015.MMM...	2015.MMP00462	IOIM Missing M...	Global	evento_agregado	1	Desapacion/...	Aparecido sin v...	Sin info
991	1	22/09/2026 10:1...	IOIM-2015.MMM...	2015.MMP00463	IOIM Missing M...	Global	evento_agregado	2	Desapacion/...	Aparecido sin v...	Sin info
992	1	22/09/2026 10:1...	IOIM-2015.MMM...	2015.MMP00464	IOIM Missing M...	Global	evento_agregado	2	Desapacion/...	Aparecido sin v...	Sin info
993	1	22/09/2026 10:1...	IOIM-2015.MMM...	2015.MMP00465	IOIM Missing M...	Global	evento_agregado	2	Desapacion/...	Aparecido sin v...	Sin info
994	1	22/09/2026 10:1...	IOIM-2015.MMM...	2015.MMP00466	IOIM Missing M...	Global	evento_agregado	1	Desapacion/...	Aparecido sin v...	Sin info
995	1	22/09/2026 10:1...	IOIM-2015.MMM...	2015.MMP00467	IOIM Missing M...	Global	evento_agregado	1	Desapacion/...	Aparecido sin v...	Sin info
996	1	22/09/2026 10:1...	IOIM-2015.MMM...	2015.MMP00468	IOIM Missing M...	Global	evento_agregado	1	Desapacion/...	Aparecido sin v...	Sin info
997	1	22/09/2026 10:1...	IOIM-2015.MMM...	2015.MMP00469	IOIM Missing M...	Global	evento_agregado	95	Desapacion/...	Aparecido sin v...	Sin info
998	1	22/09/2026 10:1...	IOIM-2015.MMM...	2015.MMP00470	IOIM Missing M...	Global	evento_agregado	1	Desapacion/...	Aparecido sin v...	Sin info
999	1	22/09/2026 10:1...	IOIM-2015.MMM...	2015.MMP00471	IOIM Missing M...	Global	evento_agregado	3	Desapacion/...	Aparecido sin v...	Sin info
1000	1	22/09/2026 10:1...	IOIM-2015.MMM...	2015.MMP00472	IOIM Missing M...	Global	evento_agregado	1	Desapacion/...	Aparecido sin v...	Sin info
NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL

staging.desaparecidos_raw: copia cruda con id_carga y fecha_carga.

Iteración 2 · Reglas completas

Objetivo. Aplicar todas las reglas R1 a R9 con ETL Principal.

Ajustes realizados.

- Se habilitó ETL Principal y se deshabilitó ETL Iteracion 1.
- Se agregaron DER_Atípicos (límites del análisis IQR de la Etapa 2), LKP_TipoEvento con el catálogo ref.tipo_evento_homologado y CSPL_FechaFaltante.
- Se agregó la rama de revisión con motivo por regla y Union All.

Resultado. 337.444 recibidos, **331.611 aceptados**, 28 duplicados, **5.805 en revisión** (todas por fecha faltante). Las 337.444 filas encontraron su tipo de evento en el catálogo.

id_carga	iteracion	registros_recibidos	registros_aceptados	registros_duplicados	registros_revision	cuadra
1	1	337444	337416	28	0	SI
2	2	337444	331611	28	5805	SI

Verificación: recibidos = aceptados + duplicados + revisión en ambas iteraciones (columna 'cuadra' = SI).

```

SELECT
1  (SELECT COUNT(*) FROM revision desaparecidos_pendientes
2  WHERE id_carga = 2 AND motivo_revision = 'fecha faltante') AS filas_en_revision,
3  (SELECT COUNT(*) FROM revision desaparecidos_pendientes r
4  WHERE r.id_carga = 2
5  AND EXISTS (SELECT 1 FROM staging desaparecidos_raw s
6  WHERE s.id_registro = r.id_registro
7  AND s.id_carga = 2 AND s.fecha IS NULL)) AS confirmadas_sin_fecha_en_origen,
8  (SELECT COUNT(*) FROM dbo desaparecidos_final
9  WHERE id_carga = 2 AND fecha IS NULL) AS filas_sin_fecha_en_final;
11

```

filas_en_revision	confirmadas_sin_fecha_en_origen	filas_sin_fecha_en_final
5805	5805	0

Verificación de la regla de fecha: 5.805 en revisión, las 5.805 confirmadas sin fecha en staging y 0 filas sin fecha en la tabla final.

```

SELECT
1  COUNT(DISTINCT f.tipo_evento) AS categorias_tipo_evento,
2  SUM(f.fuera_catalogo) AS fuera_del_catalogo,
3  SUM(CAST(f.num_personas_atipico AS INT)) AS num_personas_atipicos,
4  SUM(CAST(f.anio_atipico AS INT)) AS anio_atipicos,
5  SUM(CASE WHEN (f.num_personas_atipico = 1 AND NOT (f.num_personas > 1))
6  OR (f.num_personas_atipico = 0 AND f.num_personas > 1)
7  OR (f.anio_atipico = 1 AND NOT (f.anio < 1974))
8  OR (f.anio_atipico = 0 AND f.anio < 1974)
9  THEN 1 ELSE 0 END) AS marcas_incorrectas,
10 COUNT(*) - COUNT(DISTINCT CONCAT(f.id_origen, '|', f.fuente)) AS duplicados_restantes
11 FROM (
12 SELECT d.*
13 CASE WHEN EXISTS (SELECT 1 FROM ref tipo_evento_homologado r
14 WHERE r.valor_canonico = d.tipo_evento)
15 THEN 0 ELSE 1 END AS fuera_catalogo
16 FROM dbo desaparecidos_final d
17 WHERE d.id_carga = 2
18 ) AS f;
19

```

categorias_tipo_evento	fuera_del_catalogo	num_personas_atipicos	anio_atipicos	marcas_incorrectas	duplicados_restantes
8	2	13390	606	0	0


Calidad de la tabla final: 8 categorías de tipo_evento, 13.390 y 606 atípicos marcados, 0 marcas incorrectas y 0 duplicados.

Iteración 3 · Repetibilidad e idempotencia

Objetivo. Comprobar que el proceso da el mismo resultado con los mismos datos y que cargar dos veces el mismo lote no duplica la tabla final.


Ajustes realizados. Se vaciaron las tablas de datos, se cambió User::Iteracion a 3 y se ejecutó el paquete dos veces seguidas sin limpiar entre ejecuciones.

Resultado. Primera ejecución: 331.611 aceptados y 5.805 en revisión, igual que la iteración 2. Segunda ejecución: 0 aceptados; las 331.611 filas salieron por la coincidencia de LKP_Idempotencia (sección 9).



Control Flow de la iteración 3.

*Iteración 3,
primera ejecución:
inicio del Data
Flow.*



*Iteración 3, primera ejecución: 331.611 a la
tabla final y 5.805 a revisión.*

Resumen de las iteraciones

Carga	Iteración	Recibidos	Aceptados	Duplicados	Revisión	Ya existían	Cuadra
1	1	337.444	337.416	28	0	0	SI
2	2	337.444	331.611	28	5.805	0	SI
3	3 (1. ^a ejecución)	337.444	331.611	28	5.805	0	SI
4	3 (2. ^a ejecución)	337.444	0	28	5.805	331.611*	SI*

7. Manejo de errores y tratamiento de los registros en revisión

Estrategia

El paquete no se detiene por un registro defectuoso: cada regla que puede rechazar una fila tiene una salida propia que la desvía a la tabla de revisión, con el valor original y el motivo. Solo los errores estructurales (archivo ausente o con otra estructura, base de datos inaccesible) detienen la ejecución.

Punto de control	Configuración	Motivo registrado	Filas (iter. 2)
CONV_Tipos	Error y truncamiento: redirigir fila	Error de conversion en columna #n	0
LKP_TipoEvento	Sin coincidencia: redirigir a salida no coincidente	tipo_evento no encontrado en catalogo de homologacion	0
CSPL_FechaFaltante	Condición ISNULL(fecha_conv)	fecha faltante	5.805
ORIGEN_CSV, destinos OLE DB	Fallar componente	— (detiene el paquete)	—

Estructura del registro en revisión

Cada fila en revision.desaparecidos_pendientes guarda id_registro, id_original y fuente para ubicarla en el origen; **campo_conflictivo**, **valor_original** (sin modificar) y **motivo_revision** para saber qué falló; e **id_carga** para saber en qué ejecución ocurrió. Al cruzarla con staging por id_registro e id_carga se recupera la fila completa tal como llegó.

Composición de los 5.805 registros en revisión

Reproduciendo las reglas sobre el dataset consolidado, los registros sin fecha se concentran en SIEVCAC (≈ 5.670), seguidos de Medicina Legal (≈ 126), la encuesta propia (7) y la entrevista (1).

En muchos de ellos el año sí existe y falta el mes o el día; por ejemplo:

id_registro	fuelle	anio	mes	fecha	Motivo
SIEVCAC-1,022,578	SIEVCAC (CNMH)	2002	(vacío)	(vacío)	fecha faltante
ML-10067	Medicina Legal	(vacío)	(vacío)	(vacío)	fecha faltante
ENCUESTA-14	Encuesta propia	1987	(vacío)	(vacío)	fecha faltante
ENTREVISTA-1	Entrevista	2006	(vacío)	(vacío)	fecha faltante

Procedimiento de tratamiento

- **Consultar** los pendientes de la última carga agrupados por motivo y fuente.
- **Corregir en el origen** cuando el dato exista (por ejemplo, completar la fecha desde el archivo de la fuente) y regenerar el CSV; la siguiente carga los aceptará y el Lookup de idempotencia evitará duplicar lo ya cargado.
- **Decidir la regla** para los casos con año pero sin mes o día: se propone aceptarlos con fecha aproximada (1 de enero o día 1 del mes) y una bandera *fecha_aproximada*, para no perder casos útiles para análisis por año.

8. Comparación de resultados

Conteos

Etapas del flujo	Iteración 1	Iteración 2	Iteración 3 (1.ª)
Filas leídas del CSV	337.444	337.444	337.444
Filas en staging	337.444	337.444	337.444
Rechazadas por conversión	0	0	0
Rechazadas por tipo de evento	—	0	0
Duplicados eliminados	28	28	28
Rechazadas por fecha faltante	—	5.805	5.805
Cargadas en la tabla final	337.416	331.611	331.611

Indicadores de calidad

Indicador	Antes (CSV consolidado)	Después (tabla final, iter. 2)
Registros	337.444	331.611 (+ 5.805 en revisión, 28 duplicados)
Unicidad (id_original + fuente)	99,99 % · 28 duplicados	100 % · 0 duplicados
Registros sin fecha	5.808 (1,72 %)	0
Valores únicos de tipo_evento	11 (uno con NBSP)	8
Columnas con tipo de dato correcto	0 de 23 (todo texto)	9 columnas convertidas a numérico/fecha; resto texto
Nulos estructurales documentados	0 (vacíos silenciosos)	region, departamento y municipio con 'No aplica'
Atípicos marcados	Sin marca	13.390 (num_personas) y 606 (anio)
Complejidad global	78,50 %	≈ 83,6 %**
Conciliación de conteos	—	recibidos = aceptados + duplicados + revisión: SI

9. Evidencia de que repetir el mismo lote no genera duplicados

La idempotencia se garantiza en dos niveles: **LKP_Idempotencia** desvía las filas cuyo id_registro ya está en la tabla final, y la restricción UNIQUE (id_registro) de dbo.desaparecidos_final impide en la base de datos cualquier inserción repetida que llegara a escaparse del paquete.



Figz Segunda ejecución de la iteración 3: las 331.611 filas salen por 'Lookup Match Output' hacia RC_YaExistan; ninguna llega a DEST_Final.

```

(C1 rows affected)
PS C:\WINDOWS\System32> sqlcmd -S "(localdb)\MSSQLLocalDB" -d DesaparicionPersonasETL -Q "SELECT COUNT(*) FROM dbo.desaparecidos_final"

331611

(C1 rows affected)
PS C:\WINDOWS\System32> sqlcmd -S "(localdb)\MSSQLLocalDB" -d DesaparicionPersonasETL -W -Q "SELECT id_carga, iteracion, registros_recibidos, registros_aceptados, registros_duplicados, registros_revision FROM control.control_cargas ORDER BY id_carga"

id_carga iteracion registros_recibidos registros_aceptados registros_duplicados registros_revision
-----
1 1 3374444 337416 28 0
2 2 3374444 331611 28 5805
3 3 3374444 331611 28 5805
4 3 3374444 0 28 5805

(C4 rows affected)
PS C:\WINDOWS\System32>

```

Figura 23. Verificación con sqlcmd: la tabla final sigue con 331.611 filas y control_cargas registra la ejecución 4 con 0 aceptados.

10. Enlaces

Repositorio GitHub	https://github.com/Teffy-glicth/Poyecto_DesaparicionPersonas
Aplicación Flask publicada	https://poyecto-desaparicionpersonas-kefg.onrender.com
Video de demostración	https://www.youtube.com/watch?v=A8Gn9X58u3g

11. Conclusiones y mejoras propuestas

- El paquete carga 331.611 registros limpios y tipados, separa 5.805 con motivo documentado y elimina 28 duplicados; en todas las ejecuciones los conteos cuadran.
- La iteración 3 demuestra que el proceso es repetible y que una segunda carga del mismo lote no inserta filas nuevas en la tabla final.
- La trazabilidad es completa: cada fila puede seguirse desde staging hasta la tabla final o de revisión por id_registro e id_carga.
- Mejoras:** guardar *registros_ya_existian* en control_cargas; aplicar idempotencia también a revisión; aceptar fechas aproximadas cuando exista el año; revisar las 3 filas fuera de catálogo; parametrizar la ruta del CSV con un parámetro de proyecto; y, para los duplicados de SIEVCAC (misma persona con fechas distintas), decidir qué fila conservar en lugar de dejarlo al orden del Sort.