Universidad de Cundinamarca

Facultad de Ingeniería

Ingeniería de Sistemas y Computación

Minería de Datos

Etapa 6 – Conocimiento Oculto

Proyecto de Minería de Datos sobre la Desaparición de Personas

Paula Catalina Ángel Parra

Esteffy Geraldine Bachiller Carrillo

Luis Felipe Murcia Rojas

David Santiago Torres Higuera

Edison Gustavo Cañon Varela

12 de noviembre de 2026

1. Contexto, objetivo y pregunta de análisis

El proyecto estudia la desaparición de personas en Colombia a partir de fuentes oficiales, en particular el registro de Medicina Legal (SIRDEC) y el de víctimas de desaparición forzada del conflicto armado (SIEVCAC, Centro Nacional de Memoria Histórica). En las etapas anteriores se hizo un análisis descriptivo con Power BI y un análisis multidimensional con un modelo estrella. Ese trabajo mostró, entre otras cosas, que cerca de 7 de cada 10 personas registradas son hombres, que las mujeres aparecen con vida aproximadamente el doble de veces que los hombres, que en el sur del país los casos se resuelven menos y que la fuente del registro pesa más en el desenlace que el sexo de la persona.

Esta etapa busca ir más descubrir patrones que no se ven a simple vista mediante un modelo supervisado y un agrupamiento en Orange Data Mining, y contrastarlos con lo que opinan los ciudadanos en los comentarios de YouTube. Las tres preguntas que guían el trabajo son:

- **Pregunta supervisada.** Con la información disponible al momento del reporte (sexo, departamento, zona del hecho, clasificación del caso, año y mes), ¿se puede anticipar si una persona seguirá desaparecida, aparecerá con vida o aparecerá sin vida?
- **Pregunta de agrupamiento.** ¿Qué tipos de municipio existen según el perfil de sus desapariciones, y esos tipos se diferencian en la proporción de casos que siguen sin resolverse?
- **Pregunta sobre los comentarios.** ¿Qué percepciones expresa la audiencia frente a un caso de desaparición que termina en homicidio, y qué información aportan que no esté en los registros oficiales?

2. Descripción de los datos y de las transformaciones realizadas.

Los tres flujos usan dos registros oficiales ya depurados en la Etapa 2 y los comentarios públicos de un video de YouTube.

Fuente	Entidad	Nivel / publicación	Uso en esta etapa
Medicina Legal (SIRDEC)	Instituto Nacional de Medicina Legal y Ciencias Forenses	Nacional / datos.gov.co	Flujo supervisado (única fuente) y agrupamiento
SIEVCAC	Centro Nacional de Memoria Histórica (CNMH)	Nacional / datos.gov.co	Agrupamiento (peso del registro del conflicto)
Comentarios de YouTube	Canal El Rastro (video público)	YouTube Data API v3	Análisis de texto

URL del conjunto de datos de Medicina Legal: https://www.datos.gov.co/d/8hqm-7fdt

-URL del conjunto de datos de SIEVCAC: https://www.datos.gov.co/d/c59y-p4sz

-Video analizado: https://www.youtube.com/watch?v=V190AYPh-b0

Se partió del archivo depurado en la Etapa 2 (data/processed/dataset_tratado.csv). El script etapa6/preparar_datos_orange.py genera los archivos que se abren en Orange y deja documentadas las transformaciones adicionales. Los comentarios se descargaron con el script etapa6/youtube/extraer_comentarios_youtube.py.

Archivo	Unidad de análisis	Filtro aplicado	Registros
supervisado_ml_2007_2025.csv	Persona	Medicina Legal, años 2007 a 2025	135.703
clustering_municipios.csv	Municipio (código DANE)	Al menos 30 casos entre 2007 y 2025; se excluye el código 00999 (sin información)	259
comentarios_V190AYPh-b0.csv	Comentario	Todos los comentarios públicos del video	1.437

En Medicina Legal, entre el 84 % y el 95 % de los casos anteriores a 2007 figuran como «Desaparecido», según el periodo, porque en buena parte son registros retroactivos anteriores al sistema SIRDEC. Si se incluyeran, el modelo aprendería solamente que «año antiguo» equivale a «desaparecido», por ello se escoge periodo de 2007 a 2025. El año 2026 se excluye porque está incompleto.

SIEVCAC no registra la zona del hecho, y en la Etapa 5 se encontró que la fuente explica más el desenlace que el sexo. Si se mezclaran las dos fuentes, el modelo aprendería a reconocer la fuente y no el fenómeno, por ello solo se escogió Medicina Legal en el modelo supervisado.

Se excluyeron los indicadores derivados del propio desenlace (sigue desaparecida, apareció con vida o sin vida), porque no estarían disponibles al momento de predecir; el municipio, que tiene más de 1.000 categorías; la edad, que está vacía en esta fuente; las coordenadas, también vacías en Medicina Legal; y la fuente y el número de personas, que son constantes después del filtro.

Para cada municipio se calcularon seis indicadores: volumen de casos en escala logarítmica (log_casos), porcentaje de mujeres (pct_mujer), porcentaje de casos en zona rural o centro poblado (pct_rural), porcentaje clasificado como desaparición forzada presunta (pct_forzada_presunta), porcentaje de casos posteriores a 2016 (pct_post2016) y peso del registro del conflicto, es decir, casos de SIEVCAC sobre el total de SIEVCAC y Medicina Legal (pct_conflicto). Los porcentajes de desenlace se dejaron como variables meta y no intervienen en la formación de los grupos, solo se usan después para describirlos.

3. Flujos de Orange, widgets, conexiones y parámetros utilizados.

Flujo 1 - Modelo Supervisado

Widget	Conexión	Parámetros principales
File	Salida: Rank y Data Sampler	supervisado_ml_2007_2025.csv (135.703 personas). estado_victima como objetivo (target), id_registro como meta, mes como categórica.
Rank	Entrada: File	Ganancia de información, razón de ganancia, Gini y χ^2 para ordenar las seis variables predictoras.

Data Sampler	Entrada: File. Salida: modelos y Test and Score	Muestra fija de 40.000 registros, estratificada por clase y replicable.
Tree	Entrada: Data Sampler. Salida: Test and Score y Tree Viewer	Árbol no binario, mínimo 50 instancias por hoja, no dividir subconjuntos menores de 100, profundidad máxima 8, detener al 95 % de la clase mayoritaria.
Random Forest (y balanceado)	Entrada: Data Sampler. Salida: Test and Score y Feature Importance	100 árboles, entrenamiento replicable, no dividir subconjuntos menores de 10. En la variante balanceada se activa «Balance class distribution».
Logistic Regression (y balanceada)	Entrada: Data Sampler. Salida: Test and Score y Nomogram	Regularización Ridge (L2), C = 1. En la variante balanceada se activa «Balance class distribution».
Test and Score	Entrada: Data Sampler y los modelos. Salida: Confusion Matrix	Validación cruzada estratificada de 10 particiones, igual para todos los modelos; comparación por AUC.
Confusion Matrix	Entrada: Test and Score	Matriz en número de casos y en proporción de la clase real.
Tree Viewer, Feature Importance, Nomogram	Entrada: el modelo correspondiente	Feature Importance con 5 permutaciones y F1 como métrica. Nomogram con la clase objetivo seleccionada en el widget.

Flujo 2 – Agrupamiento de municipios

Widget	**Conexión**	**Parámetros principales**
File	Salida: k-Means	clustering_municipios.csv (259 municipios). Seis indicadores como variables; los porcentajes de desenlace como meta, para que no intervengan en los grupos.
k-Means	Entrada: File. Salida: Edit Domain	Inicialización k-means++, 10 reinicios, 300 iteraciones como máximo, k de 2 a 8 (se eligió k = 3), «Normalize columns» activado.

Edit Domain	Entrada: k-Means. Salida: Group By, Pivot Table, Box Plot, Scatter Plot y Geo Map	Renombra los grupos: C1 Urbanos de alto volumen, C2 Rurales con huella del conflicto, C3 Intermedios.
Group By y Pivot Table	Entrada: Edit Domain	Promedios de cada indicador por grupo (perfil de los grupos).
Box Plot, Scatter Plot, Geo Map	Entrada: Edit Domain	Comparación de variables entre grupos, volumen frente a porcentaje de mujeres y ubicación de los municipios.
Preprocess, Silhouette Plot, Distances, Hierarchical Clustering	Rama de validación	Estandarización de las variables, silueta con distancia euclidiana y dendrograma con enlace Ward como contraste.

Flujo 3 – Análisis de comentarios

Widget	Conexión	Parámetros principales
Corpus	Salida: Unique	comentarios_V190AYPh-b0.csv (1.437 comentarios), idioma español, solo la columna texto como contenido.
Unique	Salida: Statistics	Elimina duplicados exactos agrupando por texto (quedan 1.422).
Statistics	Salida: Select Rows	Cuenta palabras, menciones y emojis de tristeza.
Select Rows y Formula	Salida: Preprocess Text	Conserva comentarios con 3 o más palabras (quedan 1.337) y crea la variable tristeza.
Preprocess Text	Salida: las cuatro ramas de análisis	Minúsculas, eliminación de enlaces, tokenización con [^\W\d_]+, lematización con UDPipe en español, palabras vacías de Orange más stopwords_extra.txt y filtro de frecuencia de documento.
Topic Modelling	Entrada: Preprocess Text	LDA con 4 temas.

Sentiment Analysis y 2 Box Plot	Entrada: Preprocess Text	Método Multilingual en español; comparación por emojis de tristeza y por comentario principal frente a respuesta.
Bag of Words, Distances, Hierarchical Clustering, Select Rows, Word Enrichment	Entrada: Preprocess Text	Dendrograma cortado en 4 grupos; cada grupo se compara con el total de comentarios. FDR menor de 0,05 es significativo; entre 0,05 y 0,20, tendencia.
Corpus Viewer	Entrada: Preprocess Text	Lectura de comentarios como evidencia.

4. Implementación, evaluación y comparación de los tres modelos supervisados, con la justificación del modelo seleccionado.

El árbol de decisión es el modelo elegido pues supera al Random Forest y a la regresión logística en casi todas las métricas, con una exactitud de 0,610, aunque ningún modelo logra predecir a las personas halladas sin vida.

4.1 Planteamiento

La variable objetivo es estado_victima, con tres clases: Desaparecido, Aparecido con vida y Aparecido sin vida. Es un problema de clasificación, porque la variable a predecir es categórica. Las predictoras son sexo, departamento, zona, clasificación, año y mes. Las clases están desbalanceadas: 50,9 % Desaparecido, 43,3 % Aparecido con vida y apenas 5,8 % Aparecido sin vida. Por eso, además de la exactitud, se revisan el recall por clase y la matriz de confusión.

El flujo empieza con el widget File, que carga el archivo, y Rank, que ordena las variables según su relación con el objetivo (Figura 1). En File se asignaron los roles: estado_victima como objetivo (target), id_registro como meta y mes como variable categórica, para que no se tratara como un número continuo.

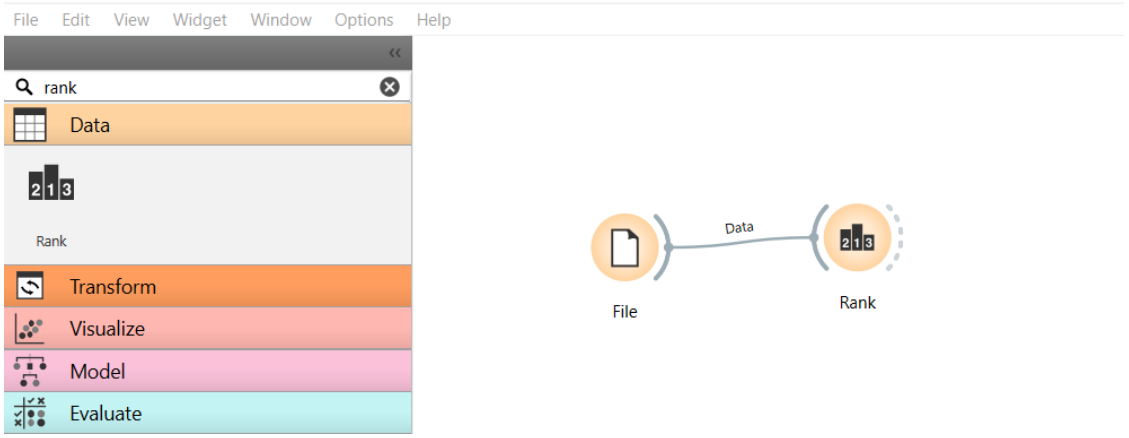
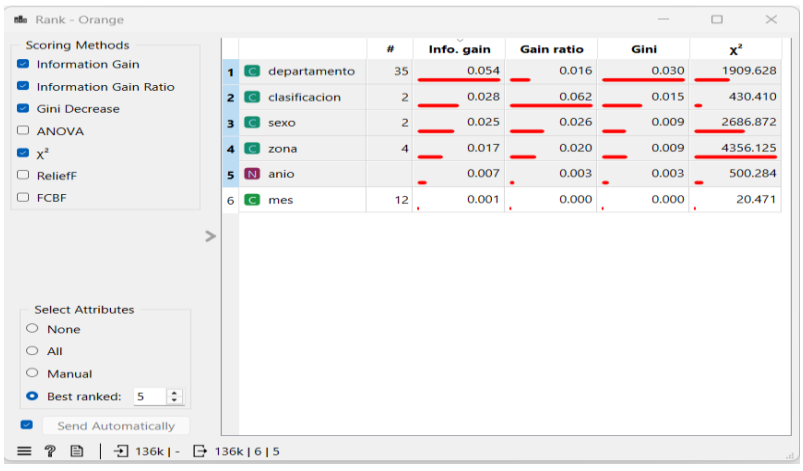


Figura 1. Inicio del flujo: el widget File carga el archivo y Rank ordena las variables según su relación con el objetivo.

4.2 Relevancia de las variables (Rank)

Rank calcula ganancia de información, razón de ganancia, Gini y χ^2 (Figura 2). El departamento es la variable con mayor ganancia de información (0,054), la clasificación del caso tiene la mayor razón de ganancia (0,062) y la zona tiene el χ^2 más alto (4.356). El año aporta poco (0,007) y el mes prácticamente nada (0,001). Se conservaron las seis variables para que los tres modelos compitieran con la misma información; el bajo aporte del mes se tiene en cuenta al interpretar los resultados.



		#	Info. gain	Gain ratio	Gini	χ²
1	departamento	35	0.054	0.016	0.030	1909.628
2	clasificacion	2	0.028	0.062	0.015	430.410
3	sexo	2	0.025	0.026	0.009	2686.872
4	zona	4	0.017	0.020	0.009	4356.125
5	anio		0.007	0.003	0.003	500.284
6	mes	12	0.001	0.000	0.000	20.471

Figura 2. Rank con ganancia de información, razón de ganancia, Gini y χ^2

4.3 Diseño del flujo y parámetros

File envía los datos a Data Sampler, que toma una muestra fija de 40.000 registros, estratificada (conserva la proporción de las tres clases) y replicable. La muestra alimenta a los modelos y a Test and Score, que evalúa a todos bajo las mismas condiciones con validación cruzada estratificada de 10 particiones. Test and Score se conecta a Confusion Matrix, y cada modelo entrenado se conecta a un widget de interpretación (Tree Viewer, Feature Importance o Nomogram). La Figura 3 muestra el flujo completo.

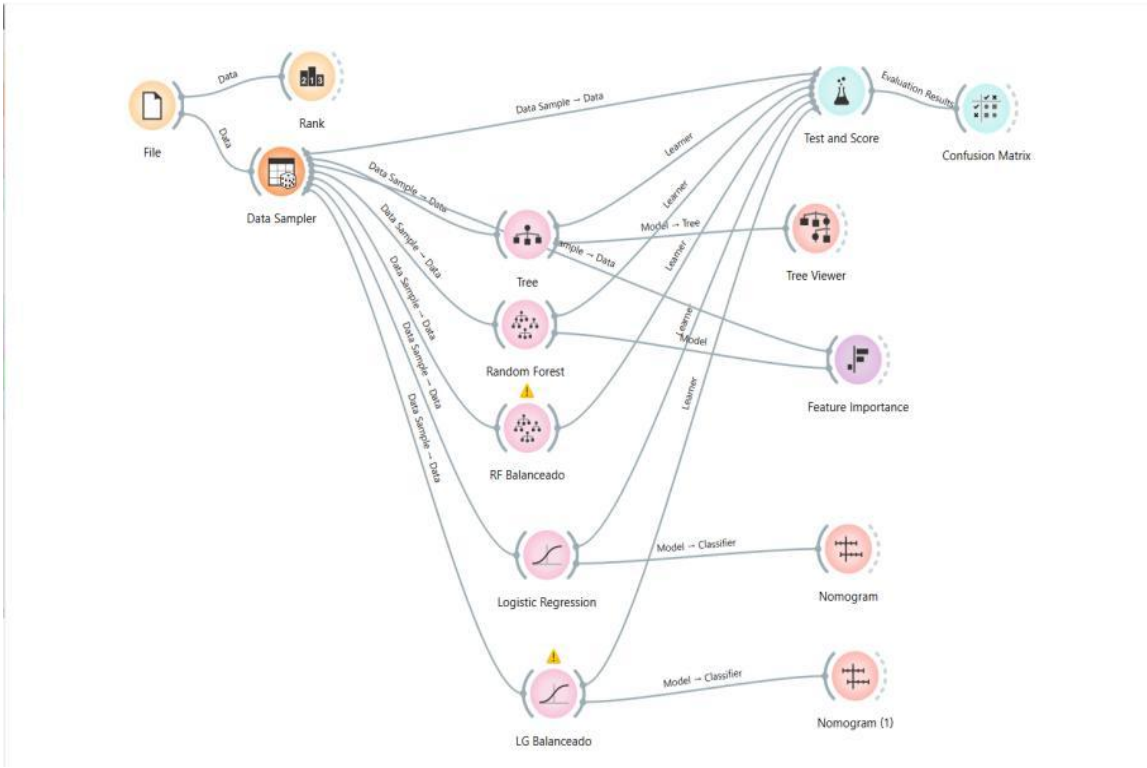


Figura 3. Flujo supervisado completo en Orange.

Modelo	Parámetros
Árbol de decisión (Tree)	Árbol no binario, mínimo 50 instancias por hoja, no dividir subconjuntos menores de 100, profundidad máxima 8, detener cuando la clase mayoritaria alcanza el 95 %. Se desactivó «Induce binary tree» porque la binarización exhaustiva no admite variables con más de 16 valores y departamento tiene 35.

Random Forest	100 árboles, entrenamiento replicable, no dividir subconjuntos menores de 10.
RF balanceado	Igual al anterior, con «Balance class distribution» activado.
Regresión logística	Regularización Ridge (L2), C = 1.
LG balanceado	Igual a la anterior, con «Balance class distribution» activado.

Los tres modelos comparados son el árbol de decisión, Random Forest y la regresión logística. Las variantes balanceadas dan más peso a la clase minoritaria. Orange advierte que esa ponderación puede disminuir el desempeño global, lo cual es esperado.

4.4 Interpretación de los modelos

Árbol de decisión (Tree Viewer). El árbol divide primero por departamento y luego combina la clasificación, la zona, el sexo y el año. La Figura 4 muestra las ramas de Meta y Nariño. En Meta, los casos clasificados como forzada presunta en zona rural siguen desaparecidos en el 83 % al 91 % de los casos; en Nariño, los casos rurales de forzada presunta ocurridos hasta 2010 siguen desaparecidos en el 96 %. En cambio, entre los casos sin clasificación de mujeres predomina «Aparecido con vida» (entre el 58 % y el 64 %, según la rama). Estas reglas muestran que el territorio, la ruralidad y el tipo de caso se combinan para definir el desenlace.

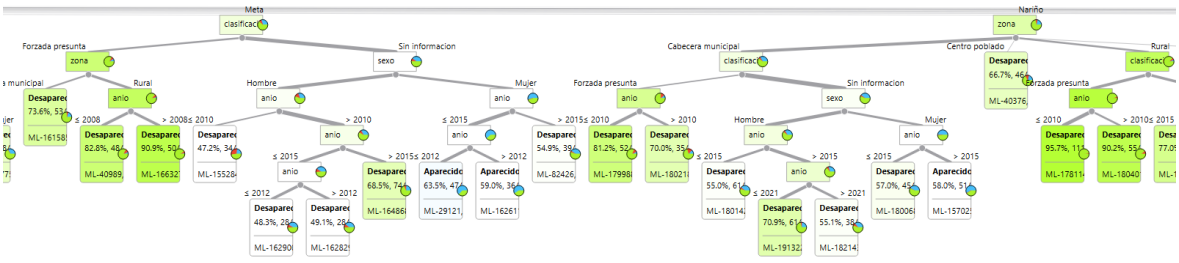


Figura 4. Fragmento del árbol de decisión con las ramas de Meta y Nariño.

Random Forest (Feature Importance). La Figura 5 mide cuánto cae el F1 al permutar cada variable. La más importante es el departamento (el F1 cae cerca de 0,15), seguida del año (0,12) y del mes (0,075); sexo, zona y clasificación pesan menos. Llama la atención que el mes resulte importante para el Random Forest cuando su ganancia de información en Rank es prácticamente cero. Esto sugiere que el bosque aprovecha combinaciones muy específicas de año y mes que no reflejan un patrón real, y es una de las razones para preferir el árbol.

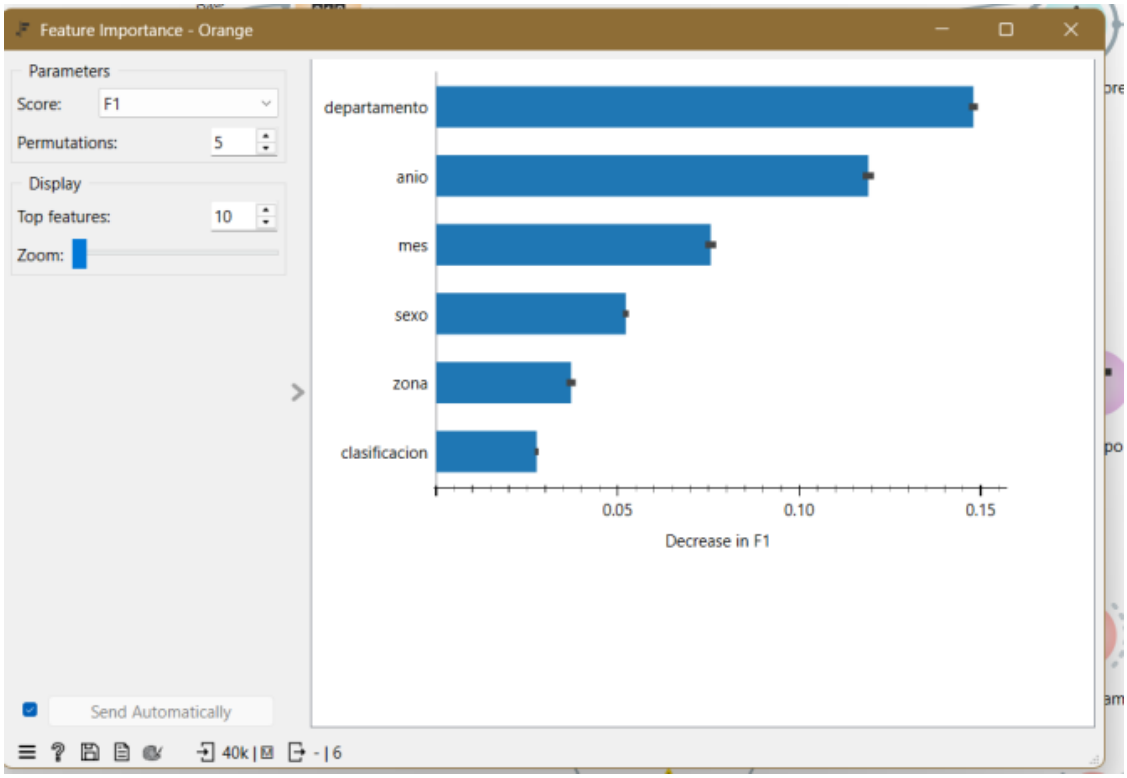


Figura 5. Disminución del F1 al permutar cada variable en el Random Forest (5 permutaciones).

Regresión logística (Nomogram). El nomograma muestra cuántos puntos suma cada valor hacia la clase seleccionada (Figura 6). Ser mujer, que el hecho ocurra en cabecera municipal o centro poblado y que el caso no tenga clasificación suman puntos; ser hombre, la zona rural y la clasificación de forzada presunta no suman. El departamento tiene la escala más amplia: Caldas, Quindío, Atlántico y Antioquia están en el extremo alto, y San Andrés, La Guajira, Cauca, Chocó y Putumayo en el

bajo. El año y el mes casi no aportan. El patrón coincide con el de la aparición con vida descrito en etapas anteriores. Con el balanceo (Figura 7), el orden de las variables se mantiene: departamento, clasificación, sexo y zona siguen siendo las que más mueven la probabilidad. Lo que cambia es la calibración, porque el modelo da más peso a la clase minoritaria.

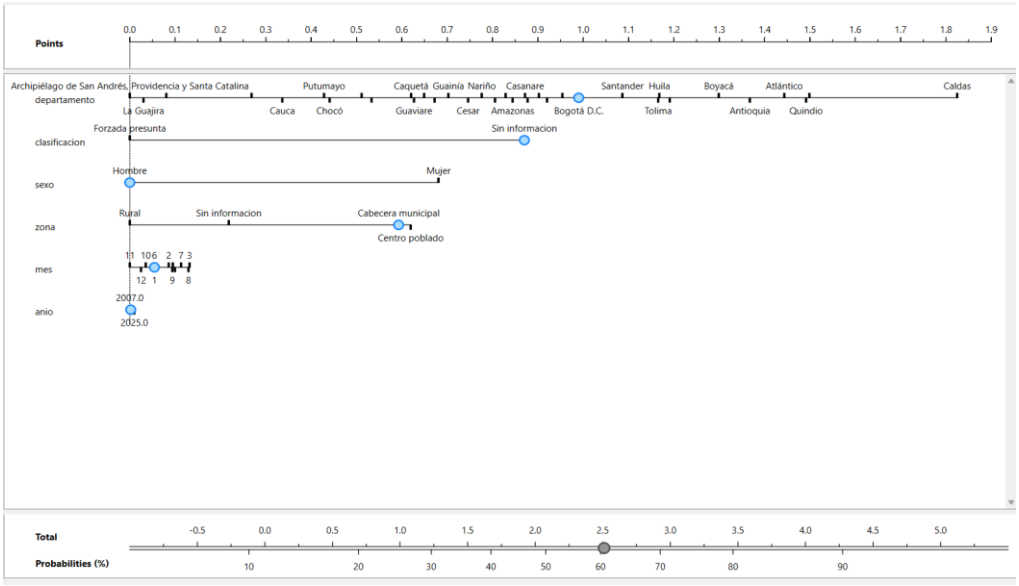


Figura 6. Nomograma de la regresión logística (clase objetivo-seleccionada en el widget).

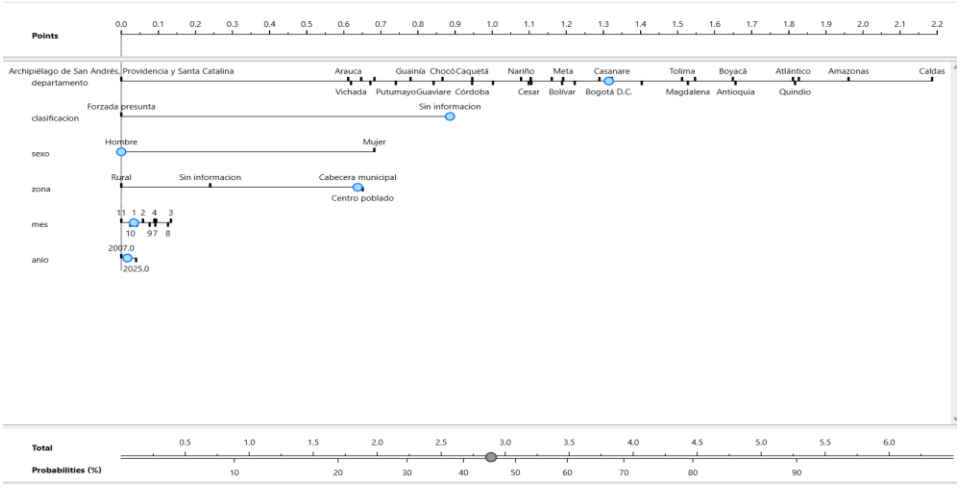


Figura 7. Nomograma de la regresión logística balanceada.

4.5 Evaluación y comparación

Test and Score promedia las métricas sobre las tres clases y compara los modelos por AUC (Figura 8).

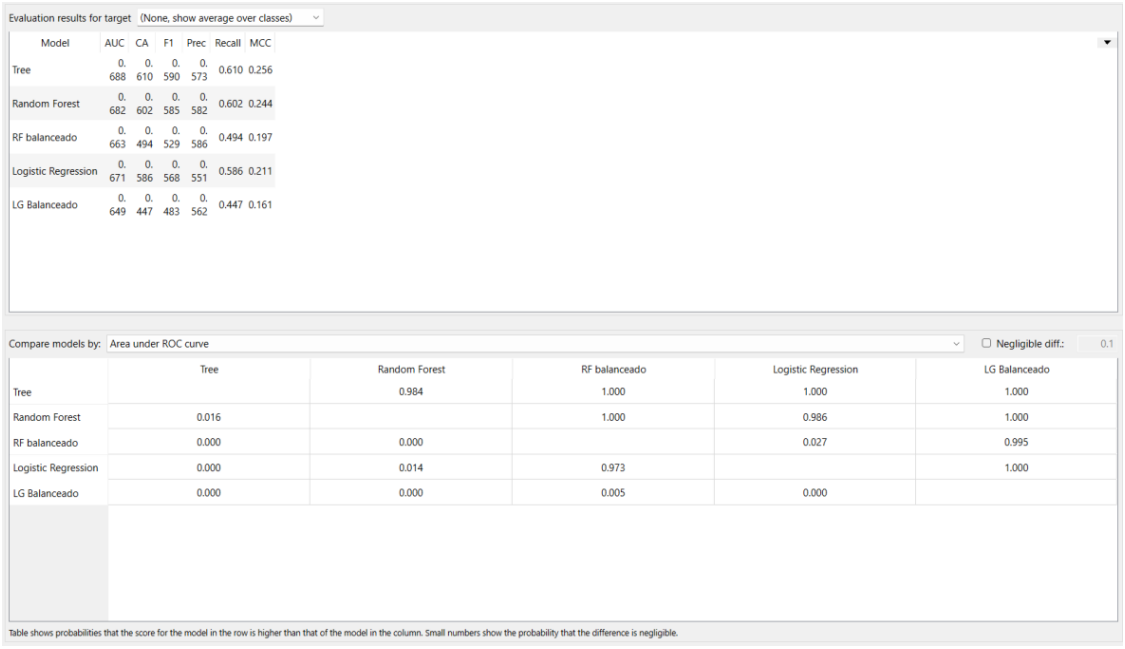


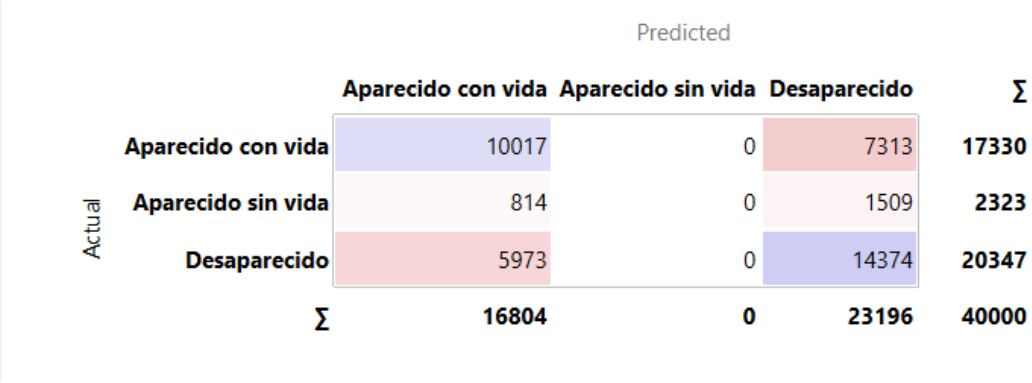
Figura 8. Test and Score: promedio sobre las clases y comparación de modelos por AUC.

Modelo	AUC	CA	F1	Precisión	Recall	MCC
Árbol	0,688	0,610	0,590	0,573	0,610	0,256
Random Forest	0,682	0,602	0,585	0,582	0,602	0,244
RF balanceado	0,663	0,494	0,529	0,586	0,494	0,197
Regresión logística	0,671	0,586	0,568	0,551	0,586	0,211
LG balanceado	0,649	0,447	0,483	0,562	0,447	0,161

El árbol obtiene los mejores valores en casi todas las métricas con una exactitud de 0,610, F1 de 0,590, AUC de 0,688 y MCC de 0,256. Un modelo que siempre respondiera «Desaparecido» acertaría el 50,9 % de las veces, así que el árbol mejora esa línea base en unos 10 puntos. La tabla inferior de la Figura 8 indica una probabilidad de 0,984 de que el AUC del árbol sea mayor que el del Random Forest, por lo que la diferencia, aunque pequeña, es consistente. Las versiones balanceadas pierden exactitud (0,494 y 0,447) porque desplazan predicciones hacia la clase minoritaria.

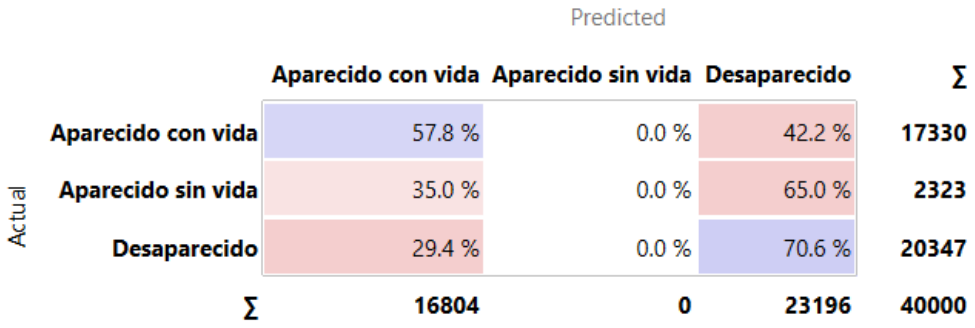
Matrices de confusión. La muestra evaluada tiene 20.347 casos Desaparecido, 17.330 Aparecido con vida y 2.323 Aparecido sin vida. Para cada modelo se presentan la matriz en número de casos y en proporción de la clase real; la diagonal de esta última es el recall de cada clase.

Árbol de decisión (Figuras 9 y 10). Reconoce el 70,6 % de los Desaparecidos y el 57,8 % de los Aparecidos con vida, pero nunca predice «Aparecido sin vida»: de esos 2.323 casos, el 65 % lo clasifica como Desaparecido y el 35 % como Aparecido con vida.



Actual \ Predicted	Aparecido con vida	Aparecido sin vida	Desaparecido	Σ
Aparecido con vida	10017	0	7313	17330
Aparecido sin vida	814	0	1509	2323
Desaparecido	5973	0	14374	20347
Σ	16804	0	23196	40000

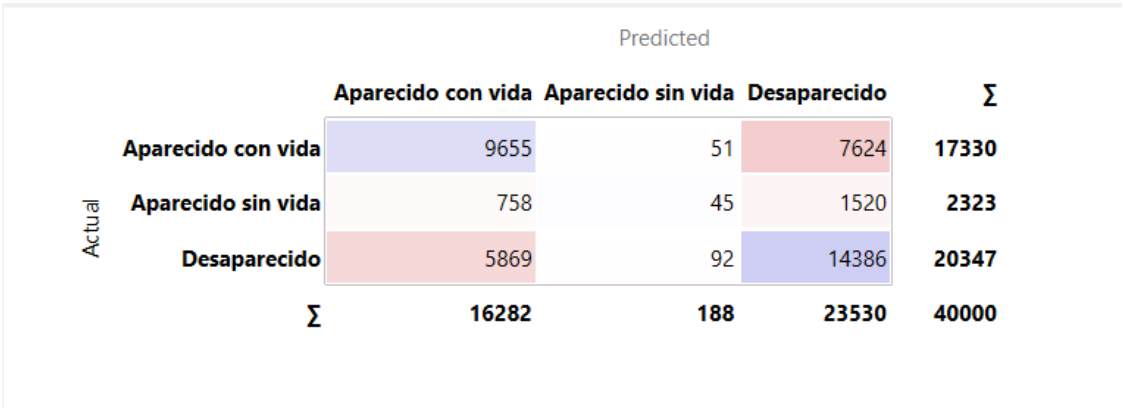
Figura 9. Árbol: número de casos.



Actual \ Predicted	Aparecido con vida	Aparecido sin vida	Desaparecido	Σ
Aparecido con vida	57.8 %	0.0 %	42.2 %	17330
Aparecido sin vida	35.0 %	0.0 %	65.0 %	2323
Desaparecido	29.4 %	0.0 %	70.6 %	20347
Σ	16804	0	23196	40000

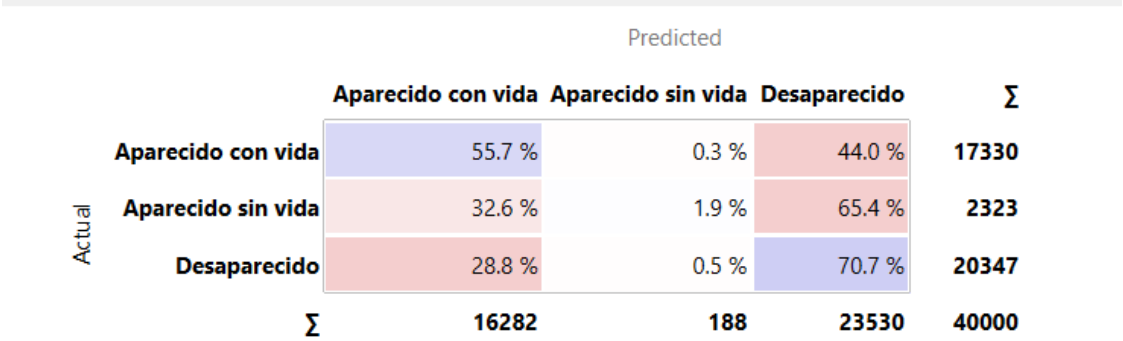
Figura 10. Árbol: proporción de la clase real.

Random Forest (Figuras 11 y 12). Resultado muy parecido al del árbol (70,7 % y 55,7 %). Solo identifica el 1,9 % de los casos sin vida: los predice 188 veces y acierta en 45.



Actual \ Predicted	Aparecido con vida	Aparecido sin vida	Desaparecido	Σ
Aparecido con vida	9655	51	7624	17330
Aparecido sin vida	758	45	1520	2323
Desaparecido	5869	92	14386	20347
Σ	16282	188	23530	40000

Figura 11. Random Forest: número de casos.



Actual \ Predicted	Aparecido con vida	Aparecido sin vida	Desaparecido	Σ
Aparecido con vida	55.7 %	0.3 %	44.0 %	17330
Aparecido sin vida	32.6 %	1.9 %	65.4 %	2323
Desaparecido	28.8 %	0.5 %	70.7 %	20347
Σ	16282	188	23530	40000

Figura 12. Random Forest: proporción de la clase real.

Random Forest balanceado (Figuras 13 y 14). El balanceo sube el recall de «Aparecido sin vida» al 36,9 %, pero baja el de Desaparecido al 48,6 %. Predice 9.225 casos como sin vida y solo 857 lo son: su precisión en esa clase es de apenas el 9 %.

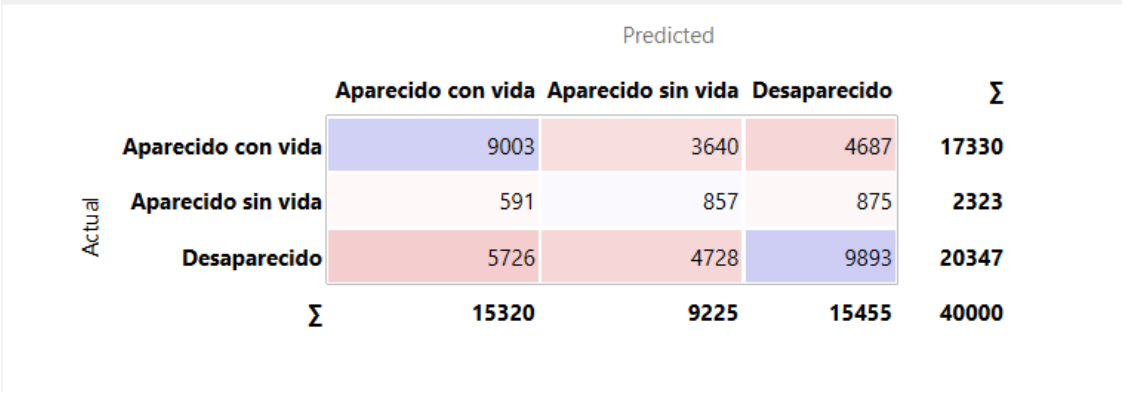


Figura 13. RF balanceado: número de casos.

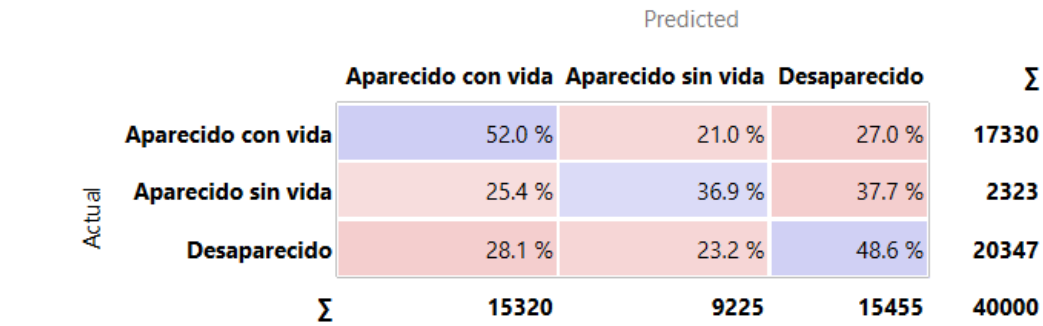


Figura 14. RF balanceado: proporción de la clase real.

Regresión logística (Figuras 15 y 16). Reconoce el 67,3 % de los Desaparecidos y el 56,3 % de los Aparecidos con vida; tampoco predice nunca la clase sin vida.

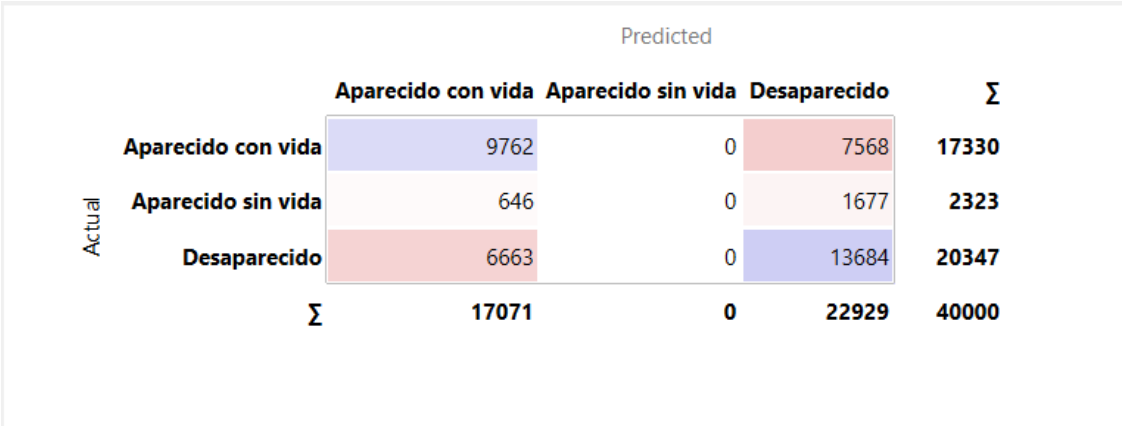
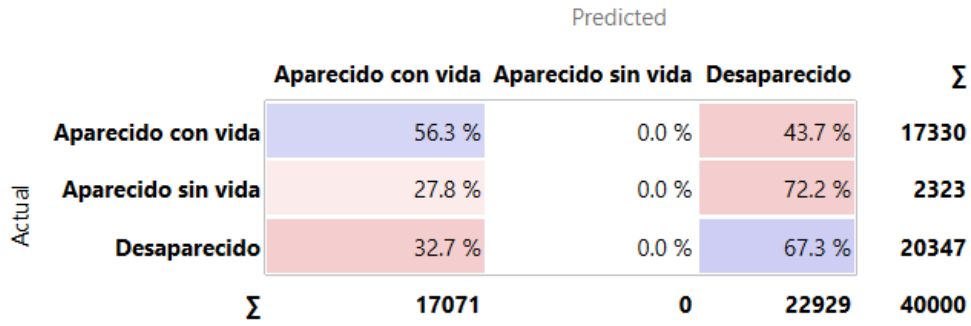


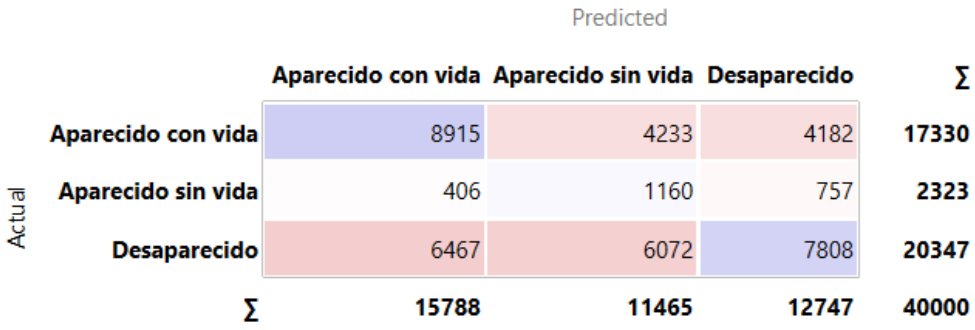
Figura 15. Regresión logística: número de casos.



Actual	Predicted: Aparecido con vida	Predicted: Aparecido sin vida	Predicted: Desaparecido	Σ
Aparecido con vida	56.3 %	0.0 %	43.7 %	17330
Aparecido sin vida	27.8 %	0.0 %	72.2 %	2323
Desaparecido	32.7 %	0.0 %	67.3 %	20347
Σ	17071	0	22929	40000

Figura 16. Regresión logística: proporción de la clase real.

Regresión logística balanceada (Figuras 17 y 18). Alcanza el mayor recall de «Aparecido sin vida» (49,9 %), a costa de reconocer solo el 38,4 % de los Desaparecidos: 6.072 personas que siguen desaparecidas quedan clasificadas como halladas sin vida. De 11.465 predicciones de sin vida, solo 1.160 son correctas (10 %).



Actual	Predicted: Aparecido con vida	Predicted: Aparecido sin vida	Predicted: Desaparecido	Σ
Aparecido con vida	8915	4233	4182	17330
Aparecido sin vida	406	1160	757	2323
Desaparecido	6467	6072	7808	20347
Σ	15788	11465	12747	40000

Figura 17. LG balanceado: número de casos.

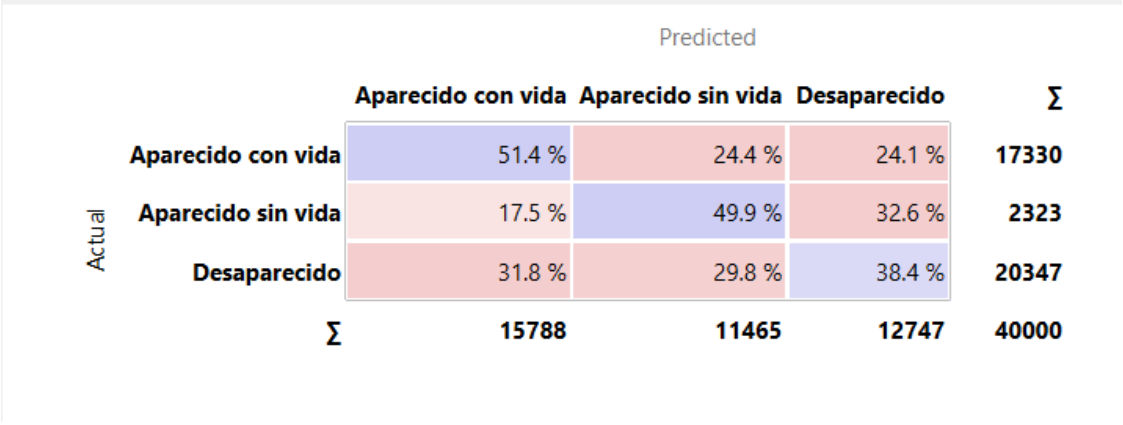


Figura 18. LG balanceado: proporción de la clase real.

Modelo	Recall con vida	Recall sin vida	Recall desaparecido
Árbol	57,8 %	0,0 %	70,6 %
Random Forest	55,7 %	1,9 %	70,7 %
RF balanceado	52,0 %	36,9 %	48,6 %
Regresión logística	56,3 %	0,0 %	67,3 %
LG balanceado	51,4 %	49,9 %	38,4 %

La exactitud global oculta que los modelos sin balancear ignoran por completo la clase «Aparecido sin vida», que representa solo el 5,8 % de los casos. Balancear permite detectar parte de esos casos, pero con tantas falsas alarmas (precisión cercana al 10 %) que el modelo deja de ser útil para las otras dos clases. Con las variables disponibles, la aparición sin vida no se puede distinguir de forma fiable.

4.6 Modelo seleccionado

Se selecciona el **árbol de decisión** por cuatro razones.

Tiene el mejor desempeño en exactitud, F1, AUC y MCC; su ventaja en AUC sobre el Random Forest es consistente (probabilidad de 0,984); no depende de variables sin

poder explicativo como el mes; y se puede leer como reglas que cualquier persona entiende, lo que permite explicar por qué clasifica un caso de una forma u otra.

Conocimiento que aporta. El desenlace de una desaparición depende sobre todo de dónde ocurre y de qué tipo de caso es. Los casos rurales clasificados como forzada presunta casi nunca se resuelven, mientras que los casos urbanos sin clasificación, especialmente de mujeres, tienen más probabilidad de terminar con la persona encontrada con vida. Esto puede orientar la priorización: los casos con perfil rural y de desaparición forzada requieren estrategias de búsqueda de largo plazo.

Limitaciones. La exactitud es moderada (61 %) y el modelo no detecta a las personas halladas sin vida. El año está confundido con el tiempo transcurrido: los casos recientes han tenido menos tiempo para resolverse. La clasificación del caso podría actualizarse después del reporte, lo que implicaría cierto riesgo de fuga de información. Por último, los resultados son asociaciones y no causas, y corresponden solo al registro de Medicina Legal.

5. Implementación, evaluación e interpretación del clustering.

El agrupamiento separa los 259 municipios en tres tipos, y aunque el desenlace no se usó para formarlos, los grupos quedan ordenados por el mismo, siguen desaparecidas el 48,1 % de las personas en los municipios urbanos y el 84,4 % en los rurales con huella del conflicto.

5.1 Planteamiento

La pregunta es qué tipos de municipio existen según el perfil de sus desapariciones. Se agruparon 259 municipios con al menos 30 casos entre 2007 y 2025, usando los seis indicadores de la Tabla 2. Como esas variables tienen escalas muy distintas (el logaritmo de casos llega a 11, mientras los porcentajes van de 0 a 1), se estandarizaron con la opción «Normalize columns» de k-Means (media 0 y desviación 1). Sin ese paso, el volumen de casos dominaría el agrupamiento. Ni el desenlace ni la variable objetivo del flujo 1 intervienen en la formación de los grupos.

Se usó k-Means con inicialización k-means++, 10 reinicios y 300 iteraciones como máximo, probando de 2 a 8 grupos. La silueta promedio fue mayor con k = 2 y algo menor con k = 3; se eligió k = 3 porque separa un grupo intermedio que con dos grupos queda mezclado, y porque los tres grupos resultan interpretables y distintos en su desenlace.

File envía los municipios a k-Means, que agrega la columna Cluster y la silueta de cada municipio. Edit Domain renombra los grupos. Desde allí salen Group By y Pivot Table (perfil de cada grupo), Box Plot, Scatter Plot y Geo Map (visualización), y una rama de validación con Preprocess (estandarización), Silhouette Plot, Distances y Hierarchical Clustering.

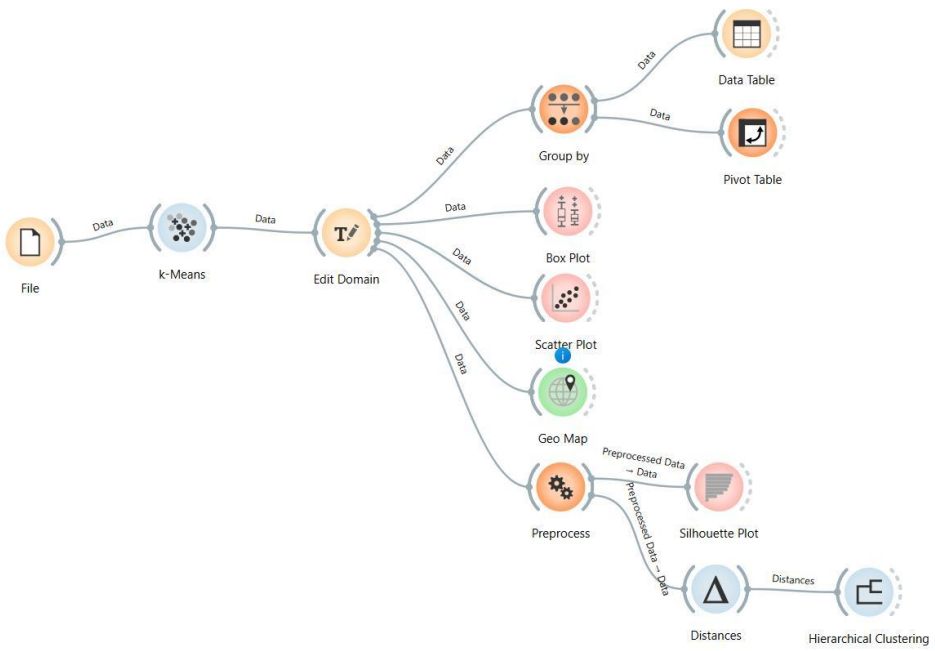


Figura 19. Flujo de agrupamiento en Orange.

Los nombres se asignaron en Edit Domain después de revisar el perfil promedio de cada grupo: C1 = Urbanos de alto volumen, C2 = Rurales con huella del conflicto y C3 = Intermedios. La Figura 21 muestra el Pivot Table conectado a la salida de Group By, con una fila por grupo.

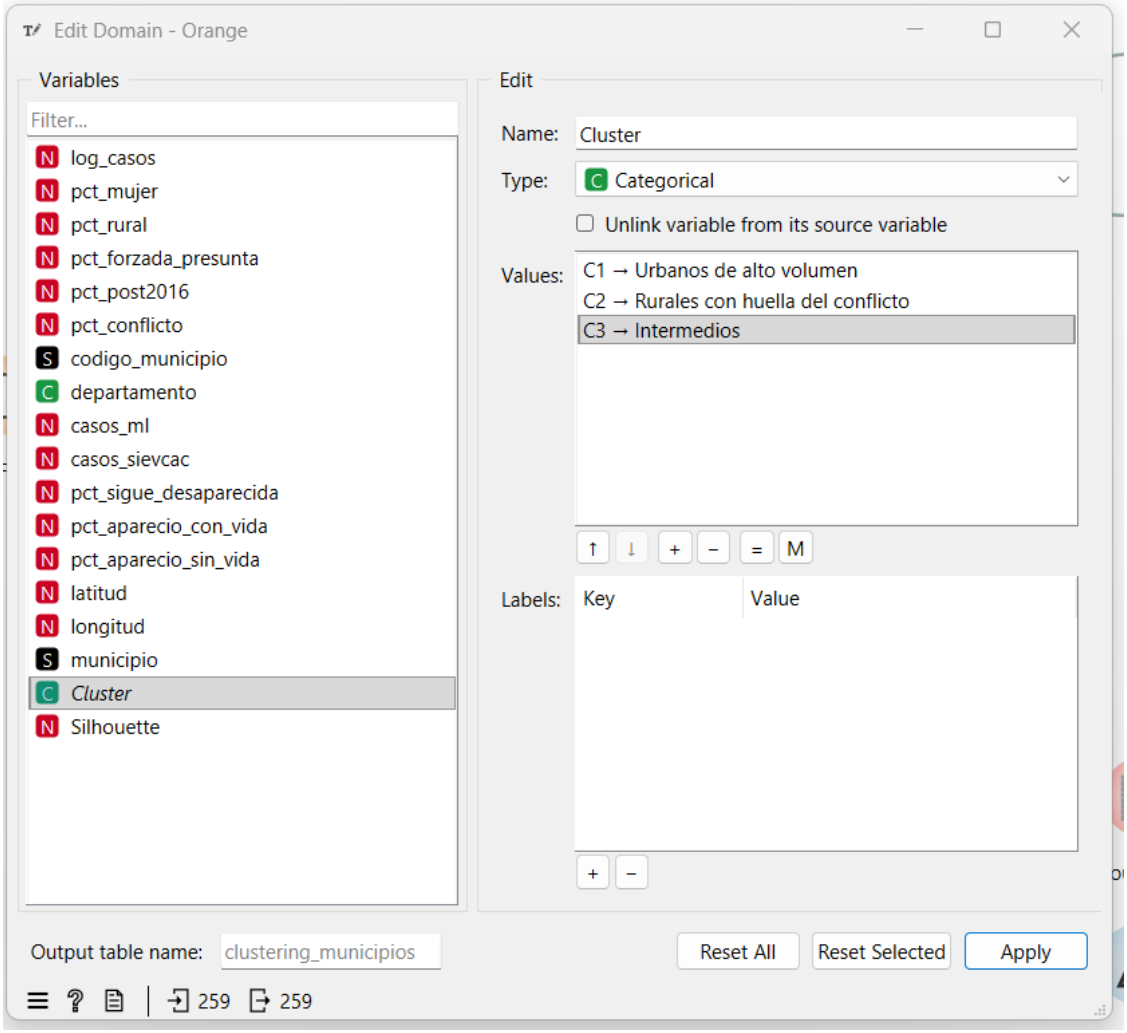


Figura 20. Asignación de nombres descriptivos a los grupos.

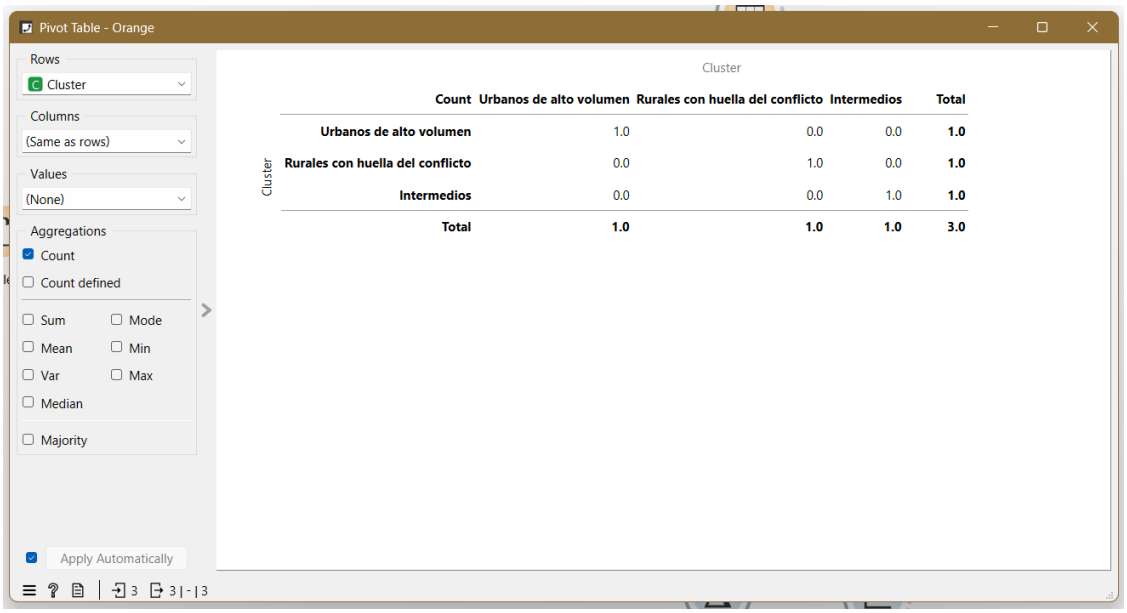


Figura 21. Pivot Table conectado a la salida de Group By (una fila por grupo).

Indicador (promedio)	Urbanos de alto volumen	Rurales con huella del conflicto	Intermedios
Municipios	53	78	128
Casos promedio en Medicina Legal	2.076	99	73
% mujeres	39,4 %	15,9 %	32,2 %
% rural o centro poblado	12,2 %	58,4 %	29,4 %
% forzada presunta	8,0 %	55,0 %	17,7 %
% de casos después de 2016	49,9 %	29,9 %	45,8 %
% conflicto (peso de SIEVCAC)	4,3 %	27,7 %	10,8 %

Departamento más frecuente	Cundinamarca	Antioquia	Antioquia
% que siguen desaparecidas (no usado para agrupar)	48,1 %	84,4 %	60,2 %

5.2 Diferencias entre grupos

Aunque el desenlace no se usó para formar los grupos, estos quedan claramente ordenados por él: en los municipios urbanos sigue desaparecido en promedio el 48,1 % de las personas, en los intermedios el 60,2 % y en los rurales con huella del conflicto el 84,4 %. El ANOVA (F = 119,5; p < 0,001) confirma que la diferencia es estadísticamente significativa.

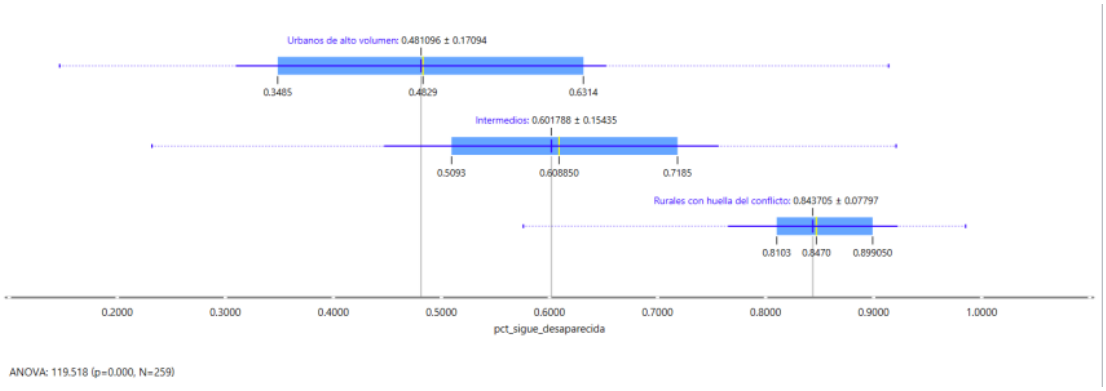


Figura 22. Porcentaje de personas que siguen desaparecidas por grupo.

La ruralidad es la variable que más separa los grupos (ANOVA F = 171,4; p < 0,001): 12,2 % en los urbanos, 29,4 % en los intermedios y 58,4 % en los rurales con huella del conflicto.

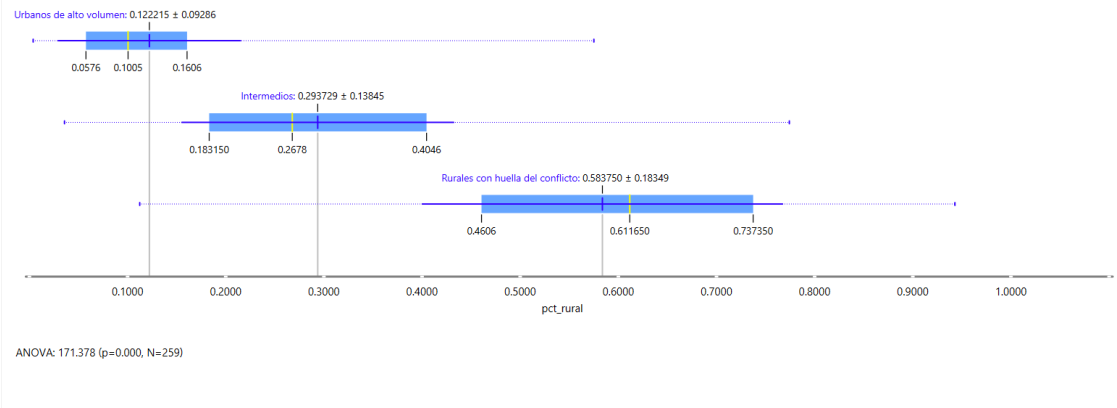


Figura 23. Porcentaje de casos en zona rural por grupo.

El peso de SIEVCAC pasa de 4,3 % en los municipios urbanos a 10,8 % en los intermedios y 27,7 % en los rurales ($p < 0{,}001$). En estos últimos, más de una de cada cuatro desapariciones registradas está ligada al conflicto armado.

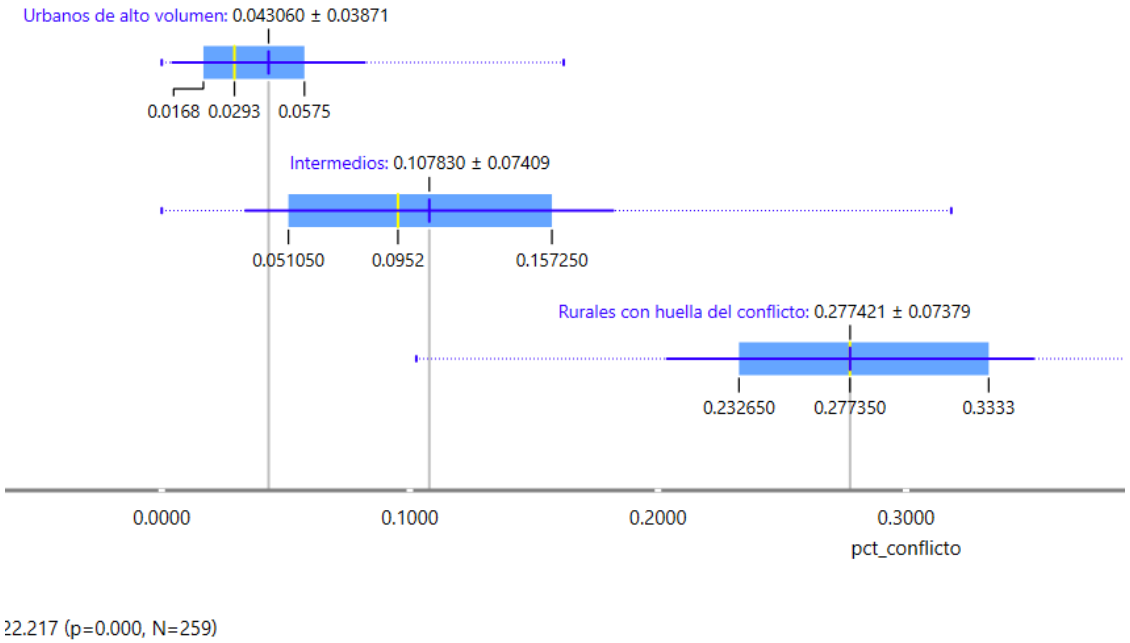


Figura 24. Peso del registro del conflicto armado por grupo.

Los municipios urbanos se ubican a la derecha (muchos casos) y con una proporción de mujeres entre el 25 % y el 55 %. Los rurales con huella del conflicto se concentran

abajo a la izquierda: pocos casos y casi solo hombres, en su mayoría por debajo del 30 % de mujeres. Los intermedios tienen pocos casos, pero una proporción de mujeres más variable.

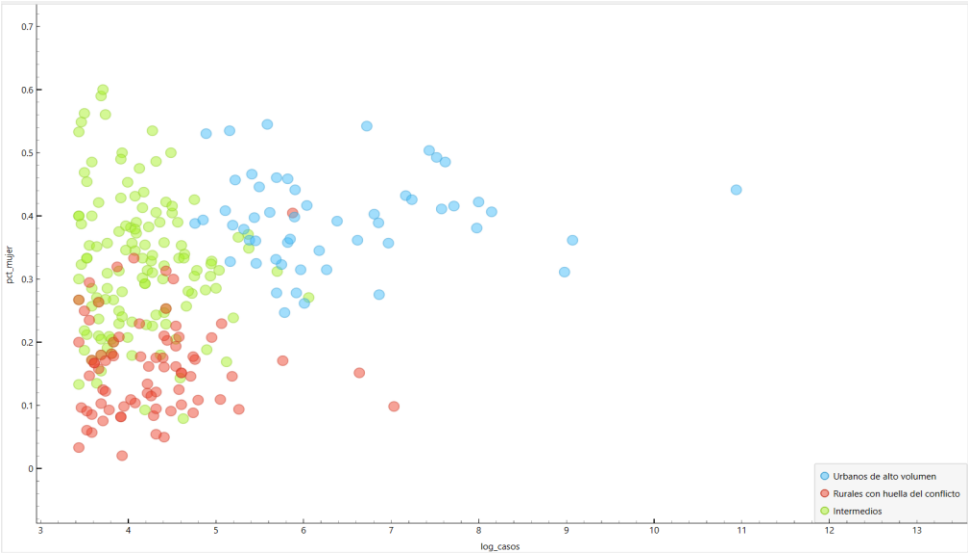


Figura 25. Volumen de casos (log_casos) frente a porcentaje de mujeres, coloreado por grupo.

El mapa revela el patrón territorial: los municipios rurales con huella del conflicto (rojo) están en la periferia: Urabá y el occidente de Antioquia, Chocó, la costa pacífica de Cauca y Nariño, Putumayo, Caquetá, Meta, Guaviare y Arauca. Los urbanos (azul) siguen el eje de las capitales andinas y del Caribe (Bogotá, Medellín, Cali, Bucaramanga, Barranquilla, Cartagena), y los intermedios (verde) se ubican alrededor de ese eje. El patrón del sur identificado en la Etapa 4 aparece aquí como parte de una franja periférica más amplia. Los 11 municipios sin coordenadas en SIEVCAC no aparecen en el mapa.

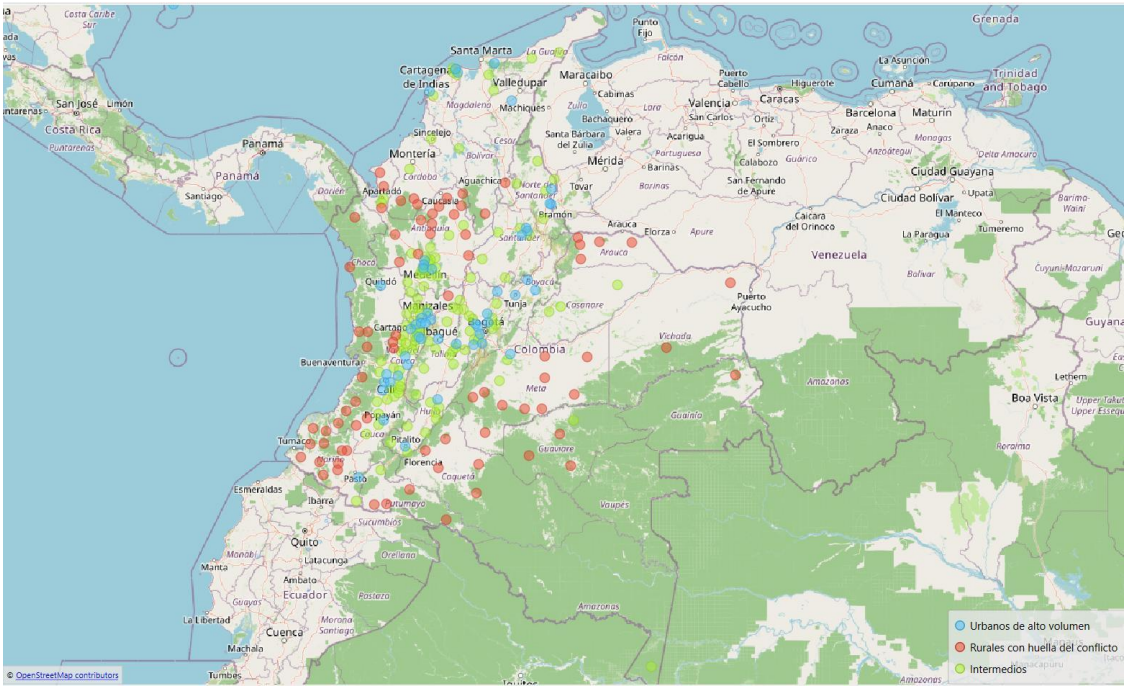


Figura 26. Ubicación de los municipios por grupo. Los 11 municipios sin coordenadas en SIEVCAC no aparecen en el mapa.

5.3 Validación del agrupamiento

La silueta promedio indica qué tan bien queda cada municipio dentro de su grupo (Figura 27, distancia euclidiana sobre los datos estandarizados). El grupo mejor definido es el de rurales con huella del conflicto (0,402), seguido de los urbanos (0,316). Los intermedios tienen la silueta más baja (0,201), coherente con su nombre: es un grupo de transición con perfiles mixtos. Todos los valores son positivos, es decir, en promedio cada municipio está más cerca de su grupo que de los demás.

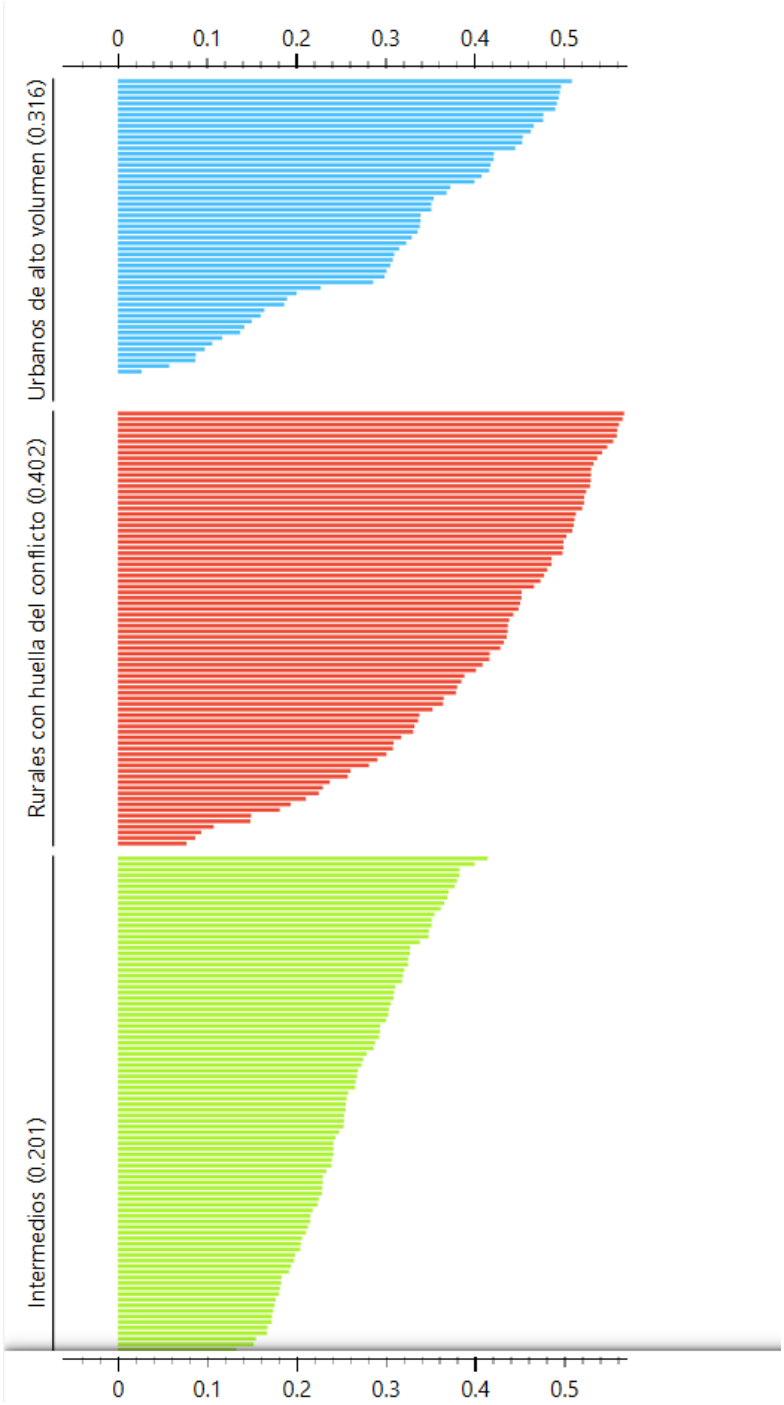


Figura 27. Silhouette Plot con distancia euclidiana sobre los datos estandarizados.

Como contraste se aplicó Hierarchical Clustering con enlace Ward (Figura 28). Une municipios vecinos del mismo departamento, identificados por su código DANE: aparecen juntos municipios de Nariño (52xxx), Meta (50xxx), Caquetá (18xxx), Cauca (19xxx), Putumayo (86xxx), Arauca (81xxx) y Guaviare (95xxx). Que un método distinto reproduzca la estructura territorial de los rurales con huella del conflicto refuerza la validez del resultado.

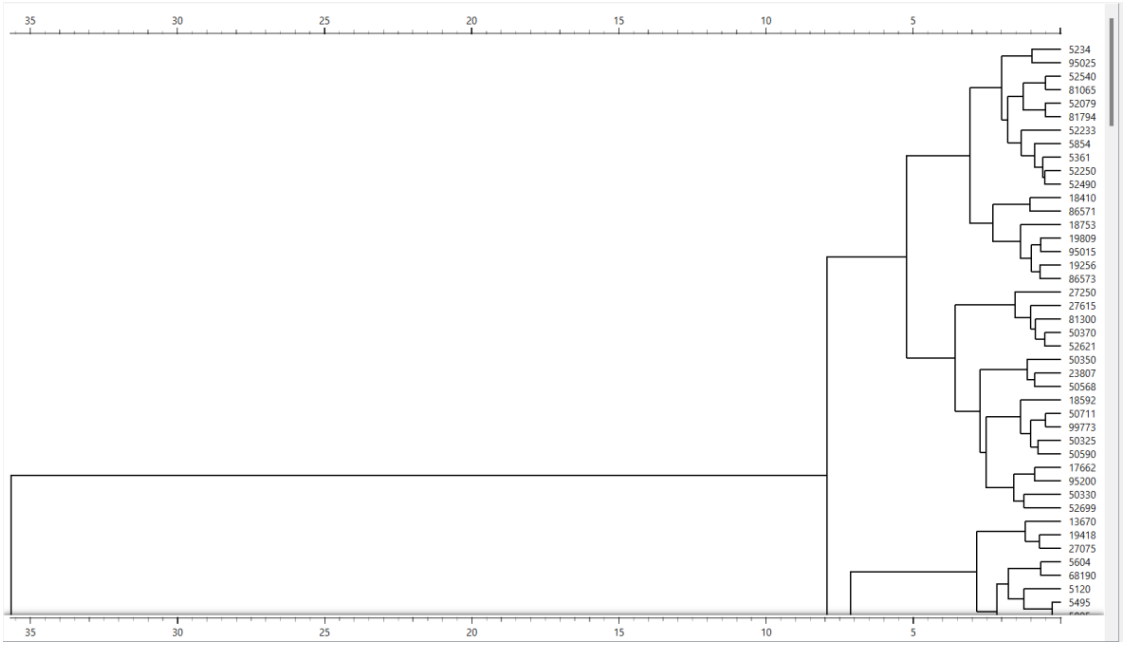


Figura 28. Dendrograma con Hierarchical Clustering (enlace Ward) como contraste.

5.4 Interpretación y uso

- Urbanos de alto volumen (53 municipios). Ciudades y municipios conurbados: concentran muchos casos, tienen la mayor proporción de mujeres, casi nada de ruralidad y poca relación con el conflicto. Es donde más casos se resuelven.

- Rurales con huella del conflicto (78 municipios). Casos rurales, más de la mitad clasificados como forzada presunta, casi exclusivamente de hombres, con el mayor peso del registro del conflicto y concentrados antes de 2016. Ocho de cada diez personas siguen desaparecidas.

- Intermedios (128 municipios). Valores medios en todos los indicadores y un desenlace también intermedio.

Patrón oculto: Grupos formados sin conocer el desenlace terminan con desenlaces muy distintos: hay 36 puntos de diferencia entre los municipios urbanos y los rurales con huella del conflicto. El problema no es solo regional, como sugería el análisis del sur en la Etapa 4, sino de un tipo de municipio que se repite en varios departamentos (por eso Antioquia es el departamento más frecuente tanto en el grupo rural como en el intermedio).

Priorizar a los 78 municipios rurales con huella del conflicto en los planes de búsqueda de largo plazo e identificación forense, y diseñar estrategias diferenciadas por tipo de municipio en lugar de usar solo la división por departamento.

6. Procedimiento de conexión a la API de YouTube, extracción, preparación y análisis de comentarios.

Los 1.337 comentarios analizados giran en torno a la justicia penal (penas, preacuerdos, cárcel) y al duelo por la víctima, información que no aparece en los registros oficiales.

Conocer cómo reacciona la ciudadanía ante un caso de desaparición que termina con la persona hallada sin vida, justamente la clase que los modelos supervisados no logran predecir, y qué elementos de contexto aparecen en esas reacciones que no están en los registros oficiales.

Se selecciono un video en español sobre un caso real de desaparición en Colombia, con más de 10 minutos de duración, comentarios habilitados y un volumen de comentarios suficiente para el análisis de texto (más de 1.000)

Dato	Valor
Título	El misterio del taxista desaparecido en Bogotá: un año de búsqueda y un final trágico - El Rastro
Canal	El Rastro
Enlace	https://www.youtube.com/watch?v=V190AYPh-b0
Publicación	4 de junio de 2024
Duración	49 min 57 s
Vistas al momento de la extracción	2.212.636
Comentarios descargados	1.437 (1.125 principales y 312 respuestas)
Fecha de extracción	9 de noviembre de 2026, 7:37 p. m. (hora de Colombia)
Herramienta	YouTube Data API v3 (endpoints videos, commentThreads y comments), script etapa6/youtube/extraer_comentarios_youtube.py

6.2 Procedimiento de conexión a la API y extracción

Obtener una clave de la YouTube Data API v3 (proyecto de Google Cloud con la API habilitada). Guardar la clave en un archivo .env local. Ese archivo no se publica en el repositorio. Ejecutar etapa6/youtube/extraer_comentarios_youtube.py, que consulta el endpoint videos (datos del video), commentThreads (comentarios principales) y comments (respuestas). El script guarda el archivo comentarios_V190AYPh-b0.csv con 1.437 comentarios.

La API tiene una cuota diaria de 10.000 unidades (cada página de 100 comentarios consume una) y solo entrega comentarios públicos y no incluye los eliminados ni los ocultos. Para no recoger información personal innecesaria, el script no guarda nombre del autor, foto ni identificador del canal; solo un número consecutivo, el texto, la fecha y los «me gusta», junto con la marca que distingue comentarios principales de respuestas.

6.3 Preparación y limpieza en Orange

De los 1.437 comentarios se eliminaron 15 duplicados exactos y 85 comentarios sin contenido analizable (solo emojis o una o dos palabras); se conserva el 93 %.

Preprocesamiento del texto (Preprocess Text). Conversión a minúsculas y eliminación de enlaces; tokenización con la expresión regular [^\W\d_]+, que conserva solo palabras y descarta números, marcas de tiempo y emojis; lematización con UDPipe en español; eliminación de palabras vacías con la lista de Orange en español más una lista propia (stopwords_extra.txt) con verbos lematizados (ser, haber, tener, hacer, ir…) y abreviaturas (q, pq, xq…); y filtro de frecuencia de documento. Los nombres de usuario citados en las respuestas quedan fuera del análisis porque son poco frecuentes, y en las capturas se evitó mostrarlos.

Después de la limpieza, Preprocess Text alimenta cuatro ramas: Topic Modelling (temas), Sentiment Analysis con dos Box Plot (tono), Bag of Words con Distances, Hierarchical Clustering, Select Rows y Word Enrichment (grupos de comentarios y palabras que los distinguen), y Corpus Viewer (lectura de comentarios como evidencia).

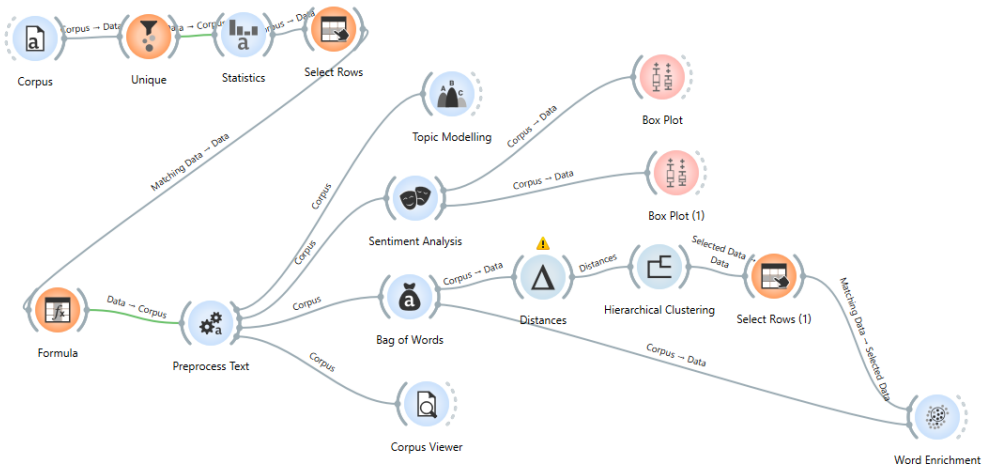


Figura 29. Flujo de análisis de comentarios en Orange.

6.4 Resultados

Temas (Topic Modelling). Con LDA y 4 temas se obtuvo una coherencia de 0,421 y una log-perplejidad de 10,39 (Figura 30).

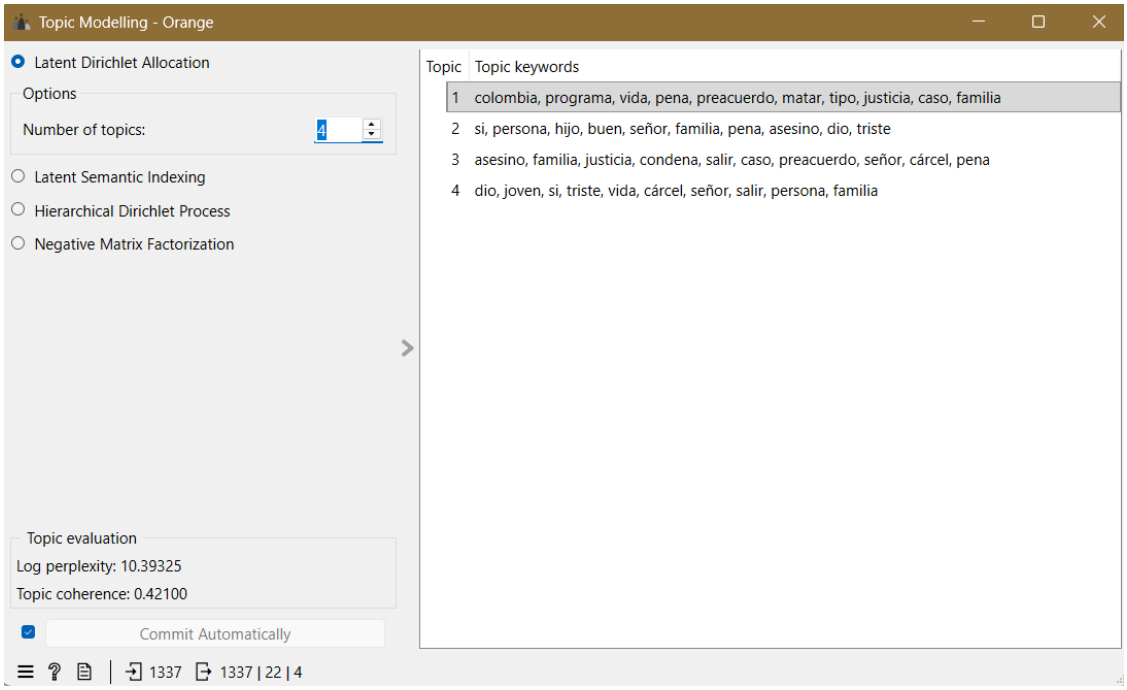


Figura 30. Modelado de temas con LDA y 4 temas.

Tema	Palabras clave	Interpretación
1	colombia, programa, vida, pena, preacuerdo, matar, tipo, justicia, caso, familia	Indignación con la justicia colombiana y comentarios sobre el programa
2	si, persona, hijo, buen, señor, familia, pena, asesino, dio, triste	Duelo y empatía con la víctima («buen señor») y su familia
3	asesino, familia, justicia, condena, salir, caso, preacuerdo, señor, cárcel, pena	Castigo, condena y rechazo a los preacuerdos
4	dio, joven, si, triste, vida, cárcel, señor, salir, persona, familia	Tristeza ante un victimario joven y religiosidad

El vocabulario de la justicia penal (pena, preacuerdo, condena, cárcel, justicia) aparece en tres de los cuatro temas, es el eje de la conversación. Junto a él aparecen el duelo por la víctima y su familia, y la expresión religiosa.

Tono (Sentiment Analysis). El tono promedio de los comentarios es negativo, alrededor de −10 en una escala de −100 a 100. Los comentarios con emojis de tristeza tienen un promedio de −11,3 frente a −9,0 de los demás, pero la diferencia no es significativa (t = 0,78; p = 0,435; Figura 31). Es decir, el léxico de sentimiento no capta la tristeza que los usuarios expresan con emojis, que se eliminan al tokenizar. El puntaje de sentimiento debe tomarse como un indicador débil. En promedio, los comentarios principales son más negativos (−10,8) que las respuestas (−4,0; Figura 32). Las respuestas tienden a ser conversacionales: muestran acuerdo, aclaran datos del caso o responden a otros usuarios.

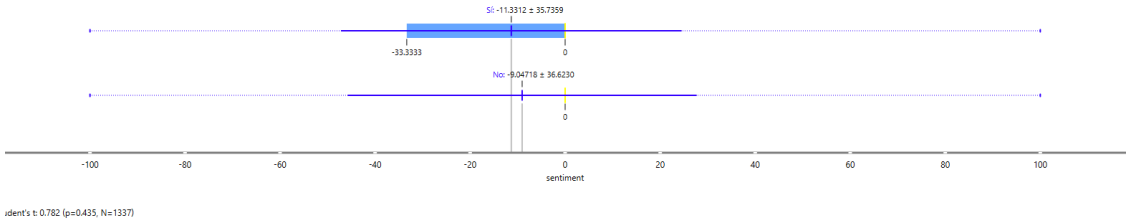


Figura 31. Sentimiento según la presencia de emojis de tristeza (método Multilingual en español).

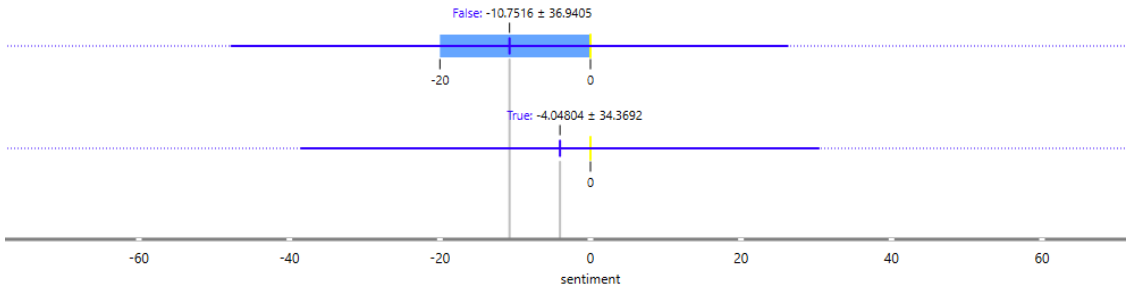


Figura 32. Sentimiento de comentarios principales (False) frente a respuestas (True).

Grupos de comentarios y Word Enrichment. Bag of Words, Distances y Hierarchical Clustering cortan los comentarios en 4 grupos. Cada grupo se separó con Select Rows y se comparó contra el total de 1.337 comentarios con Word Enrichment, que identifica las palabras significativamente más frecuentes en el grupo (Figuras 34 a 37). Las palabras con FDR menor de 0,05 se consideran significativas; las que están entre 0,05 y 0,20 se reportan como tendencia.

Grupo	Palabras destacadas (FDR)	Interpretación
C1 (385 comentarios)	pena (0,006, significativa); asesino, cárcel, salir (0,052); preacuerdo, justicia (0,084)	Exigencia de castigo y rechazo a los beneficios judiciales. Es el grupo más definido.
C2	programa (0,143, tendencia)	Comentarios sobre el programa y su valor para aprender a cuidarse.
C3	Ninguna palabra con FDR menor de 0,20	Grupo heterogéneo, sin un vocabulario propio.
C4	buen, caso, vida (0,099, tendencia)	Valoración de la víctima y del caso.

6.5 Qué aportan los comentarios

Los registros oficiales solo dicen que una persona «apareció sin vida». Los comentarios muestran lo que hay detrás, como un homicidio, una investigación que según la audiencia avanzó gracias a la familia, y una justicia percibida como benévola con el victimario. El comentario con más «me gusta» del video (1.033) resume esa percepción: «Esos malditos preacuerdos son una burla para las víctimas». Otro muy apoyado (587 «me gusta») destaca que la familia prácticamente llevó el hilo de la investigación.

El caso ocurrió en Bogotá, que pertenece al grupo de municipios urbanos, el de mejor desenlace. Aun así, los comentarios expresan desconfianza en la respuesta

institucional, por ejemplo, al preguntar por qué la denuncia de desaparición no generó una alerta. Un mejor desenlace estadístico no implica una percepción de buena atención.

La clase «Aparecido sin vida» que los modelos no logran predecir está asociada a circunstancias (homicidio, actuación de la familia, proceso judicial) que los datos no registran. Esto explica en parte la baja capacidad predictiva para esa clase y señala qué información haría falta recolectar.

Las opiniones corresponden a quienes comentaron un video de un programa de televisión sobre un caso urbano de homicidio. No representan a toda la población ni a las familias de víctimas de desaparición forzada del conflicto, que son las predominantes en el grupo rural.

7. Evidencias de los resultados, interpretación de hallazgos, limitaciones y conclusiones integradas.

7.1 Conclusiones integradas

El modelo supervisado y el agrupamiento coinciden en que el territorio, la ruralidad y el tipo de caso determinan el desenlace, y los comentarios muestran lo que los registros no capturan.

El modelo supervisado y el agrupamiento llegan, por caminos distintos, a la misma conclusión. El territorio, la ruralidad y el tipo de caso determinan el desenlace. En el árbol, el departamento, la clasificación y la zona son las variables decisivas, y la combinación rural más forzada presunta casi siempre termina en «sigue desaparecido». En el agrupamiento, los municipios rurales con huella del conflicto tienen 84 % de personas sin encontrar, frente a 48 % en los urbanos, aunque el desenlace no se usó para formar los grupos.

La aparición sin vida es invisible para los modelos, los no balanceados nunca la predicen y los balanceados la predicen con una precisión cercana al 10 %. Los

comentarios muestran que esa categoría depende de circunstancias del caso que no se registran.

Los datos ubican a Bogotá en el grupo con mejor desenlace, mientras los comentarios sobre un caso bogotano expresan desconfianza en la justicia y en la respuesta institucional. Ambas miradas son compatibles: una mide resultados agregados y la otra, la experiencia percibida de un caso.

Decisiones que podrían apoyarse en los resultados.

- Priorizar los municipios rurales con huella del conflicto en la búsqueda de largo plazo y la identificación forense.
- Usar las reglas del árbol como apoyo para clasificar casos, no como decisión automática.
- Registrar variables sobre las circunstancias del caso para mejorar la predicción.
- Considerar la percepción de impunidad al comunicar los avances de búsqueda y justicia.

Hallazgos respaldados por evidencia	Hipótesis que requieren validación
El territorio, la ruralidad y la clasificación del caso son los factores más asociados al desenlace (Rank, árbol y nomograma).	Que la menor resolución en municipios rurales se deba a capacidad institucional o difícil acceso; los datos no lo miden.
Existen tres tipos de municipio con desenlaces distintos (ANOVA $p < 0{,}001$; siluetas positivas).	Que el patrón se mantenga con datos de población (tasas por 100.000 habitantes), que no se incluyeron.
Con las variables actuales no es posible predecir la aparición sin vida (recall de 0 % a 50 % con precisión cercana al 10 %).	Que variables sobre las circunstancias del caso mejoren esa predicción.
En el video analizado, la conversación gira en torno a la justicia y los preacuerdos (temas y Word Enrichment).	Que esa percepción de impunidad se repita en otros casos y públicos; requiere más videos y otras fuentes.

7.2 Limitaciones generales

Los hallazgos de esta etapa son asociaciones, no relaciones causales, y están acotados por las siguientes limitaciones.

- Usa solo Medicina Legal y logra una exactitud moderada (61 %).

- En el modelo supervisado, el año se confunde con el tiempo transcurrido desde el reporte.

- Los grupos de municipios no consideran la población, por lo que no hay tasas por 100.000 habitantes.

- La silueta promedio fue algo mayor con k = 2; se eligió k = 3 por la interpretación de los grupos.

- El análisis de comentarios se basa en un único video, y sus opiniones no representan a toda la población.

- El puntaje de sentimiento no mostró diferencias frente a los emojis de tristeza, así que es un indicador débil.

- La escala del dendrograma de comentarios exige revisar qué columnas entraron al cálculo de distancias.

8. Referencias y enlaces de acceso a los productos entregados.

Enlace al repositorio del proyecto: https://github.com/Teffy-glicth/Poyecto_DesaparicionPersonas

URL de la aplicación Flask publicada: https://poyecto-desaparicionpersonas-kefg.onrender.com

Enlace al video de sustentación: https://youtu.be/SiBh-1_yS-Q

Referencias

- Centro Nacional de Memoria Histórica. (s. f.). *SIEVCAC – Víctimas DF Desaparición Forzada* [Conjunto de datos]. Datos Abiertos Colombia. https://www.datos.gov.co/d/c59y-p4sz
- Demšar, J., Curk, T., Erjavec, A., Gorup, Č., Hočevar, T., Milutinovič, M., … Zupan, B. (2013). Orange: Data mining toolbox in Python. *Journal of Machine Learning Research, 14*, 2349–2353.
- El Rastro. (2024, 4 de junio). *El misterio del taxista desaparecido en Bogotá: un año de búsqueda y un final trágico* [Video]. YouTube. https://www.youtube.com/watch?v=V190AYPh-b0
- Google for Developers. (s. f.). *YouTube Data API v3*. https://developers.google.com/youtube/v3
- Instituto Nacional de Medicina Legal y Ciencias Forenses. (s. f.). *Desaparecidos en Colombia – Histórico* [Conjunto de datos]. Datos Abiertos Colombia. https://www.datos.gov.co/d/8hqm-7fdt